

# *Una introducción al análisis de sobrevivencia usando el software R (Parte 1)*

Diego I. Gallardo Mateluna

Departamento de Matemática, Facultad de Ingeniería  
Universidad de Atacama  
Copiapó, Chile

Minicurso para la Sociedad Chilena de Estadística (SOCHE)

[diego.gallardo@uda.cl](mailto:diego.gallardo@uda.cl)

02 de Diciembre de 2020

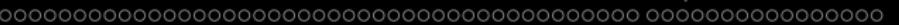
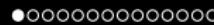




# Resumen

- Motivación.
- Elementos de interés en el análisis de sobrevivencia.
- Censura.
- Estimadores no paramétricos de la función de sobrevivencia.
- Modelos paramétricos.
- Modelos de regresión en análisis de sobrevivencia.
- Inferencia.
- Residuos.
- Otros tópicos.

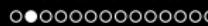




## Motivación

# Motivación



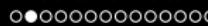


# Motivación

Asumamos que estamos interesados en el tiempo hasta que ocurra un cierto evento de interés. Usualmente este evento de interés es conocido como “falla”.

- **Medicina:** tiempo hasta que un tratamiento surta efecto.



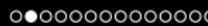


# Motivación

Asumamos que estamos interesados en el tiempo hasta que ocurra un cierto evento de interés. Usualmente este evento de interés es conocido como “falla”.

- **Medicina:** tiempo hasta que un tratamiento surta efecto.
- **Ingeniería:** tiempo hasta que un componente electrónico se deteriore.



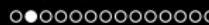


# Motivación

Asumamos que estamos interesados en el tiempo hasta que ocurra un cierto evento de interés. Usualmente este evento de interés es conocido como “falla”.

- **Medicina:** tiempo hasta que un tratamiento surta efecto.
- **Ingeniería:** tiempo hasta que un componente electrónico se deteriore.
- **Educación:** tiempo hasta que un alumno adquiera cierto conocimiento.





# Motivación

Asumamos que estamos interesados en el tiempo hasta que ocurra un cierto evento de interés. Usualmente este evento de interés es conocido como “falla”.

- **Medicina:** tiempo hasta que un tratamiento surta efecto.
- **Ingeniería:** tiempo hasta que un componente electrónico se deteriore.
- **Educación:** tiempo hasta que un alumno adquiera cierto conocimiento.
- **Ecología:** tiempo hasta que un cierto animal alcance un determinado tamaño.



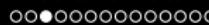


# Motivación

Asumamos que estamos interesados en el tiempo hasta que ocurra un cierto evento de interés. Usualmente este evento de interés es conocido como “falla”.

- **Medicina:** tiempo hasta que un tratamiento surta efecto.
- **Ingeniería:** tiempo hasta que un componente electrónico se deteriore.
- **Educación:** tiempo hasta que un alumno adquiera cierto conocimiento.
- **Ecología:** tiempo hasta que un cierto animal alcance un determinado tamaño.
- Etc.



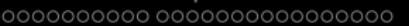
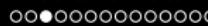


# Motivación

Es necesario definir los siguientes elementos:

- El **tiempo de inicio** del estudio debe ser definido de forma precisa, de forma que las observaciones puedan ser comparables en el origen del estudio.



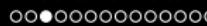


# Motivación

Es necesario definir los siguientes elementos:

- El **tiempo de inicio** del estudio debe ser definido de forma precisa, de forma que las observaciones puedan ser comparables en el origen del estudio.
- La **escala de medida**: usualmente el tiempo (cronológico).





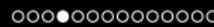
# Motivación

Es necesario definir los siguientes elementos:

- El **tiempo de inicio** del estudio debe ser definido de forma precisa, de forma que las observaciones puedan ser comparables en el origen del estudio.
- La **escala de medida**: usualmente el tiempo (cronológico).
- El **evento de interés**: nos enfocaremos en el caso en que sólo puede ocurrir debido a una única causa.



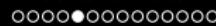




# Motivación

Nos centraremos en la **censura a la derecha**, asociada a los estudios **prospectivos**. Es decir, aquellos estudios que se diseñan y se comienzan a realizar en el presente, pero cuyos datos se analizan transcurrido un determinado tiempo, en el futuro.





# Funciones de interés en análisis de sobrevivencia

## Funciones de interés en análisis de sobrevivencia



## Funciones de interés

La variable aleatoria no negativa  $T$ , usualmente continua, que representa el tiempo de falla es generalmente especificada en análisis de sobrevida por su función de sobrevida o por la función de riesgo.



## Funciones de interés

La variable aleatoria no negativa  $T$ , usualmente continua, que representa el tiempo de falla es generalmente especificada en análisis de sobrevida por su función de sobrevida o por la función de riesgo.

**Función de sobrevida:** Es la probabilidad de una observación no fallar hasta un cierto tiempo  $t$ , es decir,

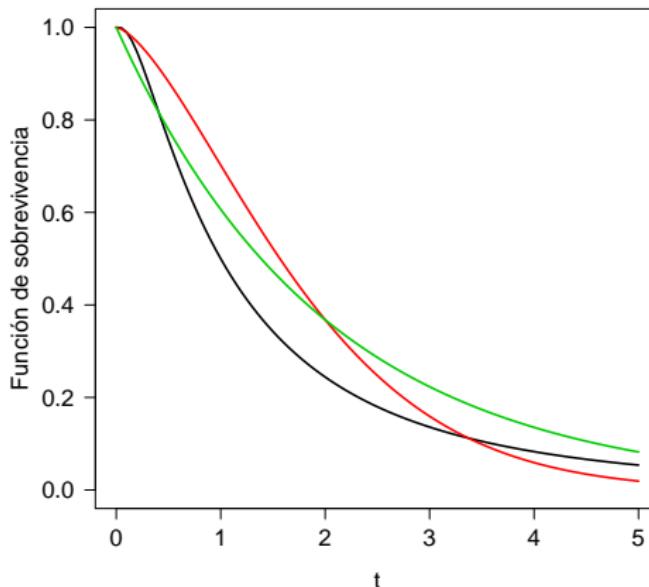
$$S(t) = P(T > t) = 1 - F(t),$$

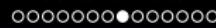
en que  $F(\cdot)$  es la función de distribución acumulada.



# Funciones de interés

Ejemplos de funciones de sobrevida.



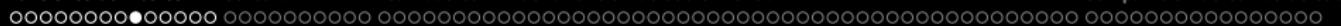


# Funciones de interés

**Función de riesgo o tasa de falla:** Es la tasa de falla instantánea en el tiempo  $t$  condicional a que la observación sobrevivió hasta el tiempo  $t$ .

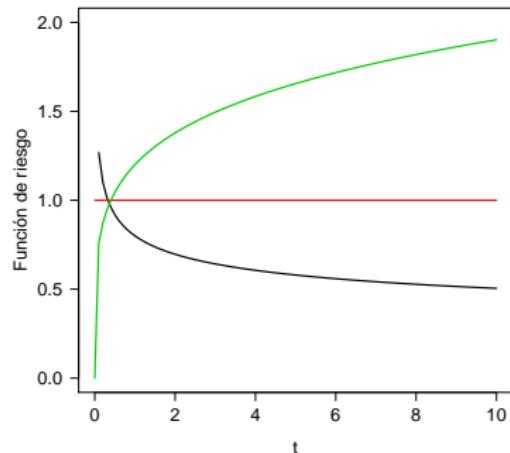
$$\lambda(t) = \lim_{h \rightarrow 0} \frac{P(t \leq T < t+h | T \geq t)}{h} = \frac{f(t)}{S(t)}$$



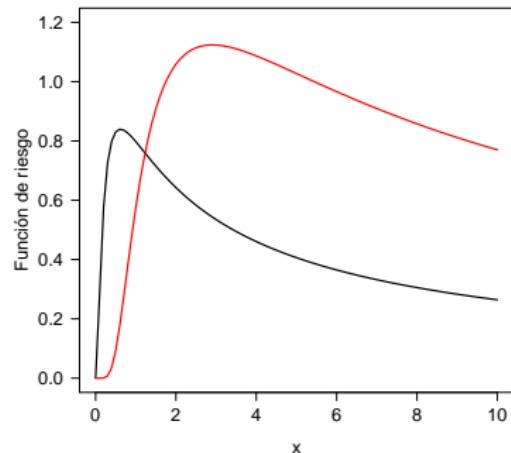


# Funciones de interés

## Ejemplo de funciones de riesgo



Monótona



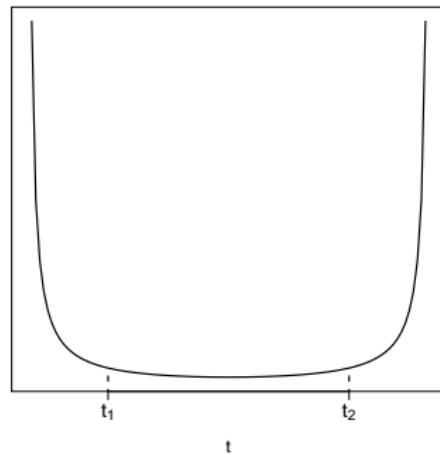
No monótona



# Funciones de interés

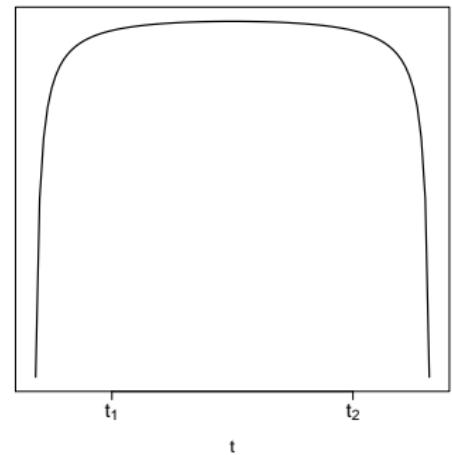
## Ejemplo de funciones de riesgo

Función de riesgo



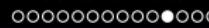
Con forma de bañera

Función de riesgo



Bañera invertida





# Funciones de interés

## Función de riesgo acumulada.

$$\Lambda(t) = \int_0^t \lambda(u)du$$



# Funciones de interés

## Función de riesgo acumulada.

$$\Lambda(t) = \int_0^t \lambda(u)du$$

Observación: Hay una relación biunívoca entre  $f(t)$ ,  $S(t)$ ,  $\lambda(t)$  y  $\Lambda(t)$ .





# Funciones de interés

	Función requerida	
Función dada	$f(t)$	$S(t)$
$f(t)$	-	$\int_t^{\infty} f(u)du$
$S(t)$	$-\frac{dS(t)}{dt}$	-
$\lambda(t)$	$\lambda(t) \exp \left\{ - \int_0^t \lambda(u) du \right\}$	$\exp \left\{ - \int_0^t \lambda(u) du \right\}$
$\Lambda(t)$	$\frac{d\Lambda(t)}{dt} \exp \left\{ - \Lambda(t) \right\}$	$\exp \left\{ - \Lambda(t) \right\}$



# Funciones de interés

Función dada		Función requerida
$f(t)$	$\lambda(t) = \frac{f(t)}{\int_t^\infty f(u)du}$	$\Lambda(t) = -\log \left( \int_t^\infty f(u)du \right)$
$S(t)$	$\lambda(t) = -\frac{dS(t)/dt}{S(t)}$	$\Lambda(t) = -\log S(t)$
$\lambda(t)$	-	$\int_0^t \lambda(u)du$
$\Lambda(t)$	$\frac{d\Lambda(t)}{dt}$	-



## Funciones de interés

Por ejemplo, para el modelo **Weibull** con parámetros  $\lambda, \nu > 0$  tenemos que

$$f(t) = \lambda\nu t^{\nu-1} \exp\{-\lambda t^\nu\}$$

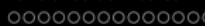
$$S(t) = \exp\{-\lambda t^\nu\}$$

$$\lambda(t) = \lambda\nu t^{\nu-1}$$

$$\Lambda(t) = \lambda t^\nu$$

con  $t > 0$ .





## *Censura*

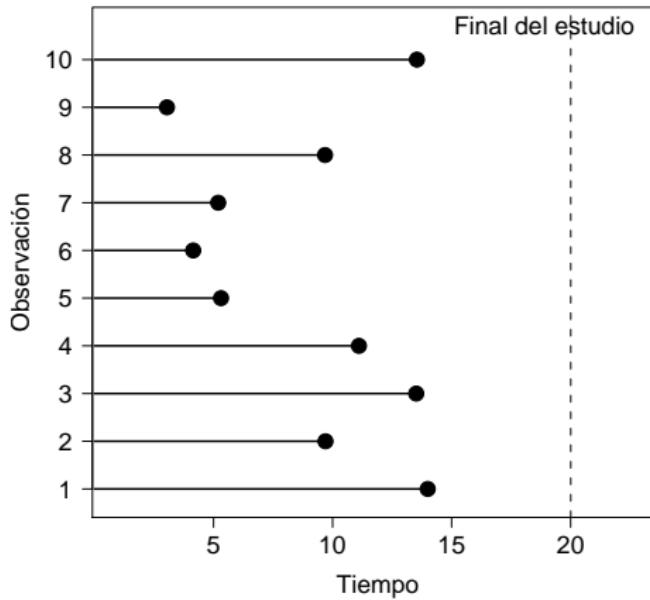
# Censura

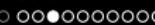




# Tipos de censura

Caso a: **datos completos.**





## Tipos de censura

Este es el caso usual que se ve en los cursos de **Inferencia Estadística**.

Podemos asumir para el tiempo de falla alguna distribución para datos positivos (**exponencial, Weibull, gamma, Birnbaum-Saunders**, etc.)



## Tipos de censura

Este es el caso usual que se ve en los cursos de **Inferencia Estadística**.

Podemos asumir para el tiempo de falla alguna distribución para datos positivos (**exponencial, Weibull, gamma, Birnbaum-Saunders**, etc.)

Bajo la suposición que las observaciones son independientes, la función de verosimilitud del modelo es dada por

$$\mathcal{L}(\theta) = \prod_{i=1}^n f(t_i; \theta),$$

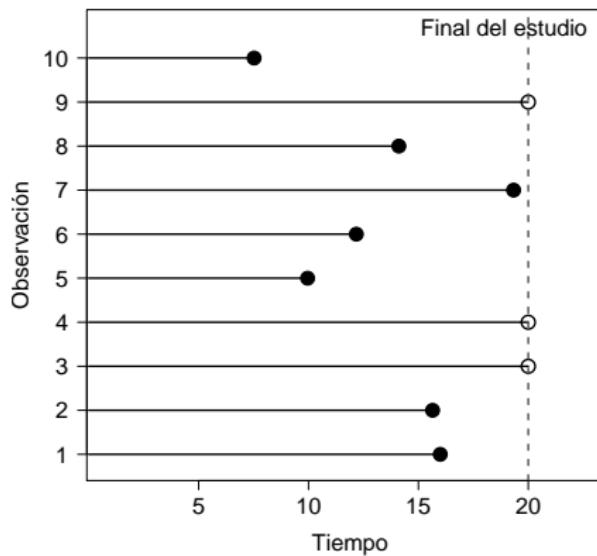
en que  $\theta$  es el vector de parámetros del respectivo modelo.



## Tipos de censura

Caso b: datos con **censura tipo I**.

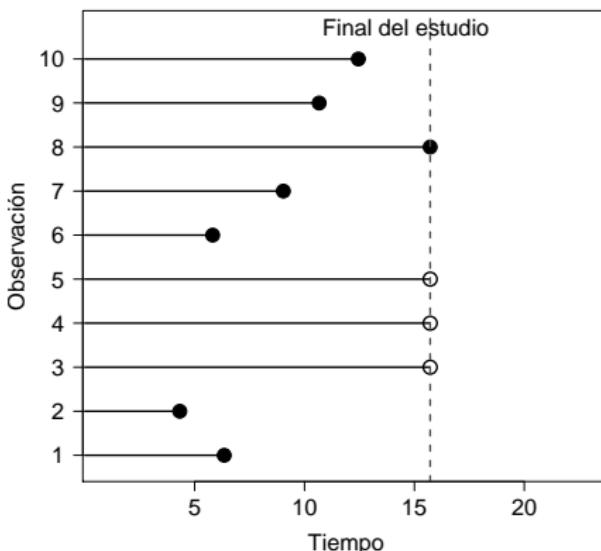
Cuando el estudio será terminado después de un período establecido de tiempo (usualmente prefijado antes de iniciar el estudio).



# Tipos de censura

Caso c: datos con **censura tipo II**.

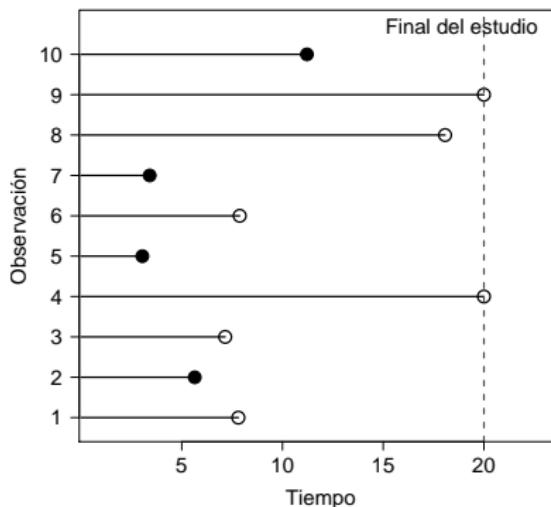
Cuando el estudio será terminado después de que un número establecido de observaciones “fallen” (usualmente prefijado antes de iniciar el estudio).



## Tipos de censura

Caso d: datos con **censura aleatoria**.

En el contexto médico es la más común en la práctica. Ocurre cuando los pacientes son retirados del estudio sin haberse observado la “falla”, o bien, porque el paciente muere por una causa diferente de la enunciada en el evento de interés.





## Tipos de censura

Otros tipos de censura (en relación al tipo de estudio).

- **Censura a la izquierda** (estudios retrospectivos).
- **Censura intervalar.**



## Representación de los datos de sobrevivencia

Los datos de sobrevivencia para el individuo  $i$  ( $i = 1, \dots, n$ ) son representados, en forma general, como

$$(t_i, \delta_i),$$

en que  $t_i$  es el **tiempo de falla o censura** y  $\delta_i$  es la **indicadora de falla**, es decir,

$$\delta_i = \begin{cases} 1 & , \text{ si } t_i \text{ es un tiempo de falla} \\ 0 & , \text{ si } t_i \text{ es un tiempo de censura} \end{cases}$$



# Representación de los datos de sobrevivencia

Desde un punto de vista general, estamos asumiendo que para cada individuo existen dos tiempos que están “**compitiendo**”:

- El tiempo de **falla**, digamos  $Y_i$ ,  $i = 1, \dots, n$ .
- El tiempo de **censura**, digamos  $C_i$ ,  $i = 1, \dots, n$ .



# Representación de los datos de sobrevivencia

Desde un punto de vista general, estamos asumiendo que para cada individuo existen dos tiempos que están “**compitiendo**”:

- El tiempo de **falla**, digamos  $Y_i$ ,  $i = 1, \dots, n$ .
- El tiempo de **censura**, digamos  $C_i$ ,  $i = 1, \dots, n$ .

Nuestras variables aleatorias son  $T_i = \min(Y_i, C_i)$  y  $\Delta_i = I(Y_i \leq C_i)$ , cuyas realizaciones son  $(t_1, \delta_1), \dots, (t_n, \delta_n)$ .



# Representación de los datos de sobrevivencia

Ejemplo:

Los tiempos de **remisión** (en meses) de pacientes con cierto tipo de cáncer son dados por

$$(15.6, 1), (13.2, 1), (20.3, 0), \dots, (6.4, 0)$$



# Representación de los datos de sobrevida

Ejemplo:

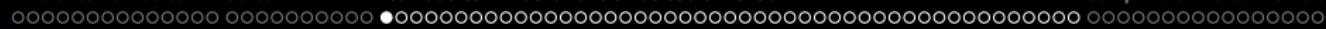
Los tiempos de **remisión** (en meses) de pacientes con cierto tipo de cáncer son dados por

$$(15.6, 1), (13.2, 1), (20.3, 0), \dots, (6.4, 0)$$

Otra forma común de presentar la información es usar el signo + para denotar los tiempos censurados. Para los tiempos mencionados anteriormente, tendríamos

$$15.6, 13.2, 20.3^+, \dots, 6.4^+$$

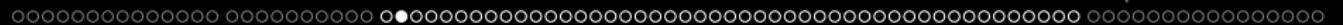




# *Estimadores NP de la función de sobrevivencia*

## Estimadores no paramétricos de la función de sobrevivencia





# Estimadores NP de la función de sobrevivencia

Ante la ausencia de censuras, el estimador natural de la función de sobrevivencia es basado en el estimador **empírico de la función de distribución acumulada**.

$$\hat{F}_{emp}(t) = \frac{1}{n} \sum_{i=1}^n I(t_i \leq t)$$



# Estimadores NP de la función de sobrevivencia

Ante la ausencia de censuras, el estimador natural de la función de sobrevivencia es basado en el estimador **empírico de la función de distribución acumulada**.

$$\hat{F}_{emp}(t) = \frac{1}{n} \sum_{i=1}^n I(t_i \leq t)$$

y

$$\hat{S}_{emp}(t) = 1 - \hat{F}_{emp}(t) = \frac{1}{n} \sum_{i=1}^n I(t_i > t).$$





# Estimadores NP de la función de sobrevida

Estimador de **Kaplan-Meier** (K-M, Kaplan and Meier, 1958) es dado por

$$\hat{S}_{KM}(t) = \prod_{j:t_j < t} \left(1 - \frac{d_j}{n_j}\right),$$

en que

- $t_1 < t_2 < \dots < t_k$ , son los  $k$  **tiempos distintos y ordenados de falla**;
- $d_j$  es el **número de fallas** en  $t_j$ ,  $j = 1, 2, \dots, k$ ;
- $n_j$  es el **número de individuos en riesgo** en  $t_j$ . Es decir, los individuos que no han fallado y que no han sido censurados hasta el instante inmediatamente anterior a  $t_j$ .



# Estimadores NP de la función de sobrevida

Observaciones sobre el estimador de K-M

- Es una función tipo “escalera”.



# Estimadores NP de la función de sobrevida

## Observaciones sobre el estimador de K-M

- Es una función tipo “escalera”.
- En ausencia de censuras, corresponde al estimador empírico de la función de sobrevida.



# Estimadores NP de la función de sobrevida

## Observaciones sobre el estimador de K-M

- Es una función tipo “escalera”.
- En ausencia de censuras, corresponde al estimador empírico de la función de sobrevida.
- Fácil de calcular.



# Estimadores NP de la función de sobrevida

## Observaciones sobre el estimador de K-M

- Es una función tipo “escalera”.
- En ausencia de censuras, corresponde al estimador empírico de la función de sobrevida.
- Fácil de calcular.
- Es **insesgado** para  $S(t)$  cuando  $n \rightarrow +\infty$ .



# Estimadores NP de la función de sobrevida

## Observaciones sobre el estimador de K-M

- Es una función tipo “escalera”.
- En ausencia de censuras, corresponde al estimador empírico de la función de sobrevida.
- Fácil de calcular.
- Es **insesgado** para  $S(t)$  cuando  $n \rightarrow +\infty$ .
- Si la observación más grande de la muestra es censurada, entonces

$$\hat{S}_{KM}(t) > 0, \quad \forall t > t_k.$$



# Estimadores NP de la función de sobrevida

## Observaciones sobre el estimador de K-M

- Es una función tipo “escalera”.
- En ausencia de censuras, corresponde al estimador empírico de la función de sobrevida.
- Fácil de calcular.
- Es **insesgado** para  $S(t)$  cuando  $n \rightarrow +\infty$ .
- Si la observación más grande de la muestra es censurada, entonces

$$\hat{S}_{KM}(t) > 0, \quad \forall t > t_k.$$

- No permite la incorporación de **covariables**.



# Estimadores NP de la función de sobrevida

Estimadores de la varianza del estimador de K-M:

- Fórmula de Greenwood.

$$\widehat{\text{Var}} \left( \widehat{S}_{KM}(t) \right) = \left[ \widehat{S}_{KM}(t) \right]^2 \sum_{j: t_j < t} \frac{d_j}{n_j(d_j - n_j)}.$$



# Estimadores NP de la función de sobrevida

Estimadores de la varianza del estimador de K-M:

- Fórmula de Greenwood.

$$\widehat{\text{Var}} \left( \widehat{S}_{KM}(t) \right) = \left[ \widehat{S}_{KM}(t) \right]^2 \sum_{j: t_j < t} \frac{d_j}{n_j(d_j - n_j)}.$$

Para un  $t$  fijo, un **intervalo de confianza** aproximado de  $100(1 - \alpha)\%$  de confianza es dado por

$$\widehat{S}_{KM}(t) \mp z_{\alpha/2} \sqrt{\widehat{\text{Var}} \left( \widehat{S}_{KM}(t) \right)},$$

en que  $z_{\alpha/2}$  es el percentil  $\alpha/2$  de la distribución normal estándar.



# Estimadores NP de la función de sobrevida

- **Transformación log-log** (Kalbfleish and Prentice, 1980). Defina
 
$$\widehat{U}(t) = \log(-\log(\widehat{S}_{KM}(t)))$$

$$\widehat{\text{Var}}\left(\widehat{U}(t)\right) = \frac{\sum_{j:t_j < t} \frac{d_j}{n_j(d_j - n_j)}}{\left[\log \widehat{S}_{KM}(t)\right]^2}.$$

Para un  $t$  fijo, un **intervalo de confianza** aproximado de  $100(1 - \alpha)\%$  de confianza es dado por

$$\widehat{S}_{KM}(t)^{\exp\left\{\pm z_{\alpha/2} \sqrt{\widehat{\text{Var}}(\widehat{U}(t))}\right\}}$$



# Estimadores NP de la función de sobrevida

Estimador de **Nelson-Aalen** (N-A, Nelson, 1972; Aalen, 1978) es dado por

$$\hat{\Lambda}_{NA}(t) = \sum_{j:t_j < t} \left( \frac{d_j}{n_j} \right),$$

En la literatura también es conocido como el estimador de **Fleming-Harrington**.



# Estimadores NP de la función de sobrevida

Estimador de **Nelson-Aalen** (N-A, Nelson, 1972; Aalen, 1978) es dado por

$$\hat{\Lambda}_{NA}(t) = \sum_{j:t_j < t} \left( \frac{d_j}{n_j} \right),$$

En la literatura también es conocido como el estimador de **Fleming-Harrington**.

El estimador de N-A para la función de sobrevida es dado por

$$\hat{S}_{NA}(t) = \exp \left\{ -\hat{\Lambda}_{NA}(t) \right\}.$$



# Estimadores NP de la función de sobrevida

Estimadores de la varianza del estimador de N-A:

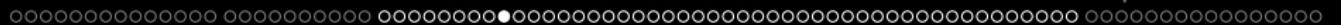
- Aalen (1978).

$$\widehat{Var} \left( \widehat{\Lambda}_{NA}(t) \right) = \sum_{j: t_j < t} \left( \frac{d_j}{n_j^2} \right).$$

Y por lo tanto,

$$\widehat{Var} \left( \widehat{S}_{NA}(t) \right) = \left[ \widehat{S}_{NA}(t) \right]^2 \sum_{j: t_j < t} \left( \frac{d_j}{n_j^2} \right).$$





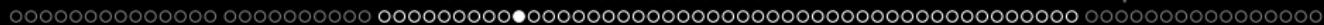
## Estimadores NP de la función de sobrevida

Datos de melanoma (paquete *timereg*). Son 205 pacientes diagnosticados con cáncer de melanoma recolectados por el Hospital universitario de Odense.

- **status**: código indicando el estado final del paciente (1:muerte debido al melanoma; 2: vivo; 3: muerte por otra causa).
- **days**: tiempo de sobrevida (en días).
- **sex**: 0: femenino; 1: masculino.
- **ulc**: presencia de úlceras. (1: presente; 0: ausente).
- **thick**: tamaño del tumor (en 1/100 mm).

Llamaremos **t1**, **d1** y **sex1** al tiempo (en años), indicadora de falla y sexo, respectivamente.





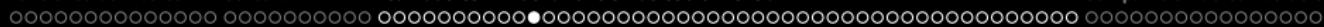
# Estimadores NP de la función de sobrevida

Datos de cáncer de pulmón (paquete *survival*)

- **status**: código indicando el estado final del paciente (1:censura; 2: muerte).
- **time**: tiempo de sobrevida (en días).
- **sex**: 1: masculino; 2: femenino.
- **ph.karno**: score de Karnofsky, indicado por un médico. (mal:0 - bien:100).

NOTA: para la observación 206 de la variable **ph.karno** hay un missing. Llamaremos **t2**, **d2** y **sex2** al tiempo (en años), indicadora de falla y sexo, respectivamente.





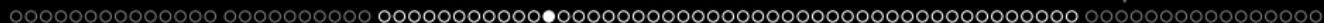
# Estimadores NP de la función de sobrevida

Por ejemplo, para definir datos de sobrevida en **R** podemos usar la función `Surv` del paquete `survival`

```
> require(survival); require(timereg)
> data(melanoma); attach(melanoma)
> t1=days/365.25
> d1=ifelse(status==1, 1, 0)
> Surv(t1, d1)

[1] 0.02737851+ 0.08213552+ 0.09582478+ 0.27104723+
[5] 0.50650240   0.55852156   0.57494867   0.63518138
[9] 0.63518138+ 0.76386037   0.80766598   0.97193703+
[13] 1.05681040   1.16632444   1.28405202   1.34976044+
[17] 1.44832307   1.70020534   1.72210815   1.80424367
...
...
```



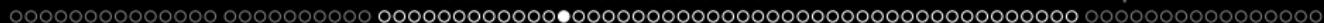


# Estimadores NP de la función de sobrevida

La función **survfit** permite calcular los estimadores de **K-M** y de **N-A**, además de sus respectivas varianzas e intervalos de confianza. La forma general de usar esta función es

```
survfit(formula, data, weights, subset, na.action,
        newdata, individual=F, conf.int=.95, se.fit=T,
        type=c("kaplan-meier","fleming-harrington", "fh2"),
        error=c("greenwood","tsiatis"),
        conf.type=c("log","log-log","plain","none"),
        conf.lower=c("usual", "peto", "modified"))
```





# Estimadores NP de la función de sobrevida

La función **survfit** permite calcular los estimadores de **K-M** y de **N-A**, además de sus respectivas varianzas e intervalos de confianza. La forma general de usar esta función es

```
survfit(formula, data, weights, subset, na.action,
        newdata, individual=F, conf.int=.95, se.fit=T,
        type=c("kaplan-meier","fleming-harrington", "fh2"),
        error=c("greenwood","tsiatis"),
        conf.type=c("log","log-log","plain","none"),
        conf.lower=c("usual", "peto", "modified"))
```

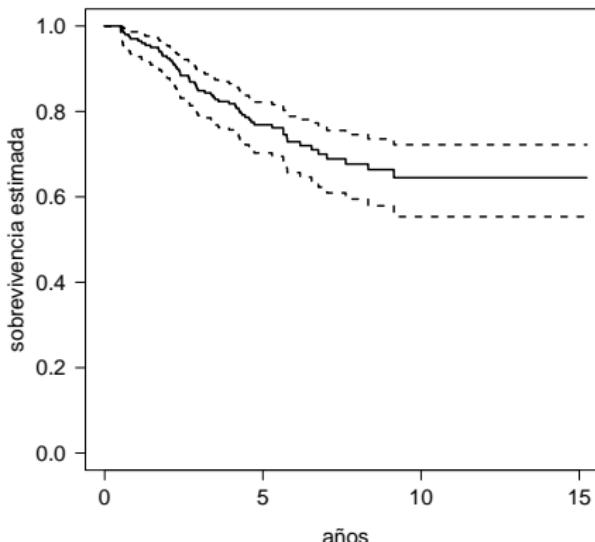




# Estimadores NP de la función de sobrevida

Por ejemplo, para calcular el estimador de K-M usamos

```
> KM.0=survfit(Surv(t1, d1) ~ 1, conf.type="log-log")
> plot(KM.0, ...)
```



NOTA: para calcular el estimador de N-A, basta adicionar  
type="fleming-harrington".



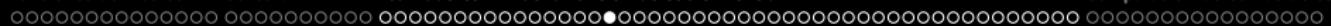
# Estimadores NP de la función de sobrevida

```
> summary(KM.O)
```

```
Call: survfit(formula = Surv(t1, d1) ~ 1, conf.type = "log-log")
```

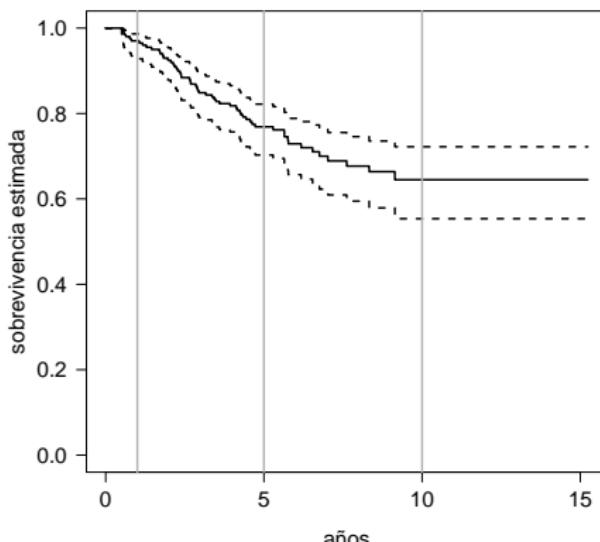
time	n.risk	n.event	survival	std.err	lower	95% CI	upper	95% CI
0.507	201	1	0.995	0.00496	0.965	0.999		
0.559	200	1	0.990	0.00700	0.961	0.998		
0.575	199	1	0.985	0.00855	0.954	0.995		
0.635	198	1	0.980	0.00985	0.948	0.992		
0.764	196	1	0.975	0.01100	0.941	0.990		
0.808	195	1	0.970	0.01202	0.935	0.986		
1.057	193	1	0.965	0.01297	0.928	0.983		
...								
6.177	80	1	0.720	0.03438	0.646	0.781		
6.538	75	1	0.710	0.03523	0.635	0.773		
6.754	69	1	0.700	0.03619	0.623	0.765		
7.023	63	1	0.689	0.03729	0.609	0.756		
7.617	57	1	0.677	0.03854	0.595	0.746		
8.329	52	1	0.664	0.03994	0.579	0.735		
9.139	35	1	0.645	0.04307	0.554	0.722		

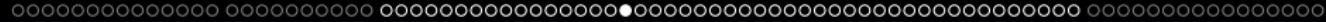




# Estimadores no paramétricos de la función de sobrevida

Por ejemplo. Si no consideramos covariables, ¿Cuál es la probabilidad de sobrevivir 1, 5 o 10 años para los pacientes con cáncer de melanoma? Es decir, ¿ $S(1)$ ,  $S(5)$  y  $S(10)$ ?





# Estimadores NP de la función de sobrevida

```
> summary(KM.0)
```

```
Call: survfit(formula = Surv(t1, d1) ~ 1, conf.type = "log-log")
```

time	n.risk	n.event	survival	std.err	lower	95% CI	upper	95% CI
0.507	201	1	0.995	0.00496		0.965		0.999
...								
0.808	195	1	0.970	0.01202		0.935		0.986
1.057	193	1	0.965	0.01297		0.928		0.983
1.166	192	1	0.960	0.01384		0.922		0.980
...								
4.726	131	1	0.769	0.03033		0.703		0.822
5.292	110	1	0.762	0.03085		0.695		0.816
5.643	95	1	0.754	0.03155		0.685		0.809
...								
7.617	57	1	0.677	0.03854		0.595		0.746
8.329	52	1	0.664	0.03994		0.579		0.735
9.139	35	1	0.645	0.04307		0.554		0.722



# Estimadores NP de la función de sobrevivencia

```
> summary(KM.0)
```

```
Call: survfit(formula = Surv(t1, d1) ~ 1, conf.type = "log-log")
```

time	n.risk	n.event	survival	std.err	lower	95% CI	upper	95% CI
0.507	201	1	0.995	0.00496		0.965		0.999
...								
0.808	195	1	0.970	0.01202		0.935		0.986
1.057	193	1	0.965	0.01297		0.928		0.983
1.166	192	1	0.960	0.01384		0.922		0.980
...								
4.726	131	1	0.769	0.03033		0.703		0.822
5.292	110	1	0.762	0.03085		0.695		0.816
5.643	95	1	0.754	0.03155		0.685		0.809
...								
7.617	57	1	0.677	0.03854		0.595		0.746
8.329	52	1	0.664	0.03994		0.579		0.735
9.139	35	1	0.645	0.04307		0.554		0.722



# Estimadores no paramétricos de la función de sobrevida

¿Cuál es la probabilidad de sobrevivir 1, 5 o 10 años para los pacientes con cáncer de melanoma?

- $\hat{S}_{KM}(1) = 0.970, (0.935 - 0.986)$
- $\hat{S}_{KM}(5) = 0.769, (0.703 - 0.822)$
- $\hat{S}_{KM}(10) = 0.645, (0.554 - 0.722)$

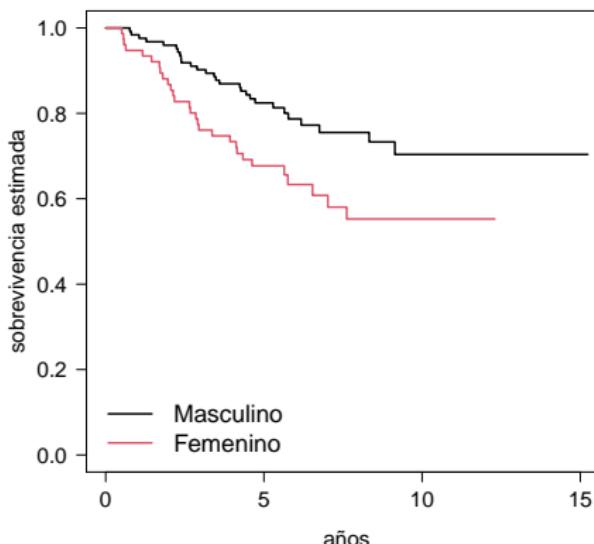
Se presenta la estimativa puntual y el respectivo Intervalo al 95% de confianza.

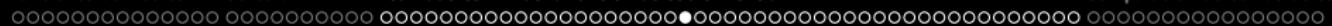


# Estimadores NP de la función de sobrevida

Si queremos calcular el estimador de K-M para los diferentes niveles de una variable usamos

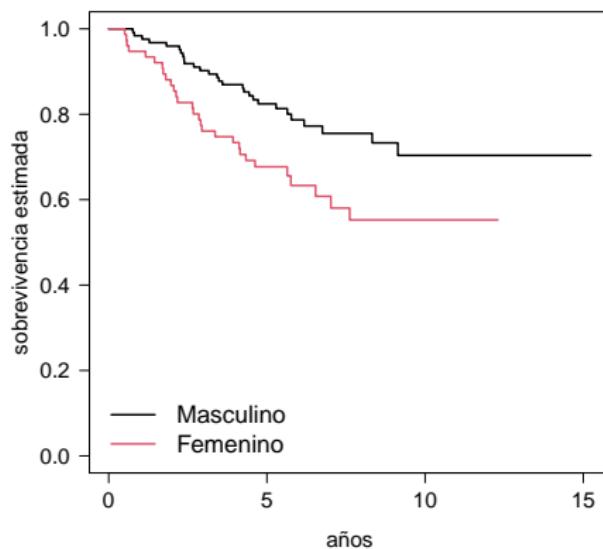
```
> KM.sex=survfit(Surv(t1, d1) ~ sex1, conf.type="log-log")
> plot(KM.sex, ...)
```

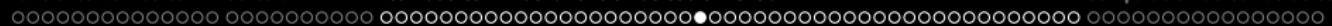




# Estimadores no paramétricos de la función de sobrevida

¿Cuál es la probabilidad de sobrevivir 1 año para las mujeres con cáncer de melanoma? ¿Y para los hombres?





# Estimadores NP de la función de sobrevida

```
> summary(KM.sex)
```

```
Call: survfit(formula = Surv(t1, d1) ~ sex1, conf.type = "log-log")
```

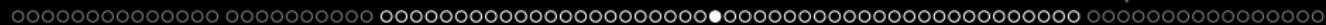
sex1=0

	time	n.risk	n.event	survival	std.err	lower	95% CI	upper	95% CI
	0.764	124	1	0.992	0.00803		0.944		0.999
	0.808	123	1	0.984	0.01131		0.937		0.996
	1.057	121	1	0.976	0.01384		0.927		0.992
	1.284	120	1	0.968	0.01593		0.916		0.988
...									

sex1=1

	time	n.risk	n.event	survival	std.err	lower	95% CI	upper	95% CI
	0.507	76	1	0.987	0.0131		0.910		0.998
	0.559	75	1	0.974	0.0184		0.899		0.993
	0.575	74	1	0.961	0.0223		0.883		0.987
	0.635	73	1	0.947	0.0256		0.866		0.980
	1.166	72	1	0.934	0.0284		0.849		0.972
	1.448	70	1	0.921	0.0310		0.832		0.964
...									



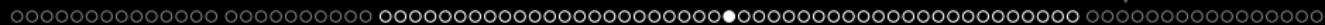


# Estimadores no paramétricos de la función de sobrevida

¿Cuál es la probabilidad de sobrevivir 1 año para las mujeres con cáncer de melanoma? ¿Y para los hombres?

- Para las mujeres
  - $\hat{S}_{KM}(1) = 0.984, (0.937 - 0.996)$ .
- Para los hombres
  - $\hat{S}_{KM}(1) = 0.947, (0.866 - 0.980)$ .

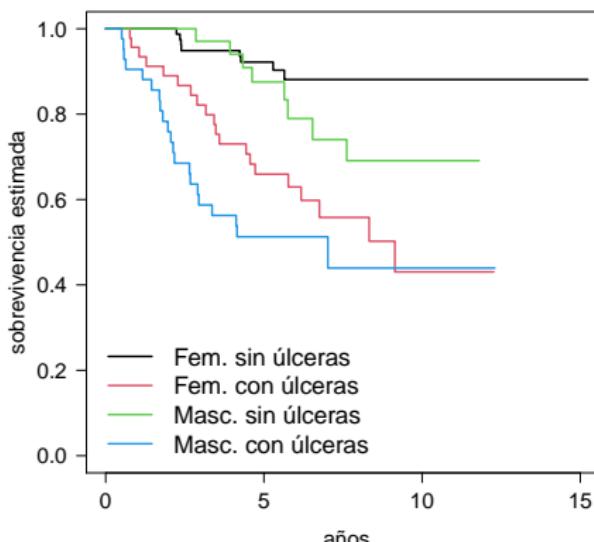




# Estimadores NP de la función de sobrevida

También es posible construir el estimador de K-M para más de una covariable de forma conjunta

```
KM.su=survfit(Surv(t1, d1) ~ sex1+ulc,  
conf.type="log-log")  
plot(KM.su, ...)
```



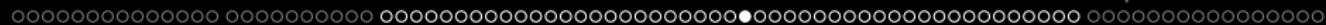


## Estimadores NP de la función de sobrevivencia

Se puede construir el estimador de K-M (o de N-A) para una covariable continua?

No, pero se puede categorizar dicha variable.





## Estimadores NP de la función de sobrevida

Se puede construir el estimador de K-M (o de N-A) para una covariable continua?

No, pero se puede categorizar dicha variable.

En el ejemplo, consideremos la variable *thick*, pero multiplicada por 100 para llevarla a mm (en vez de 1/100 mm que es la escala original).

```
> summary(thick)
```

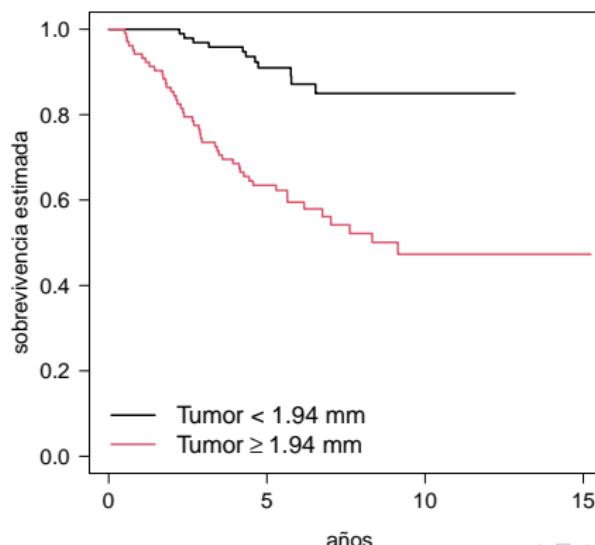
Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
0.10	0.97	1.94	2.92	3.56	17.42





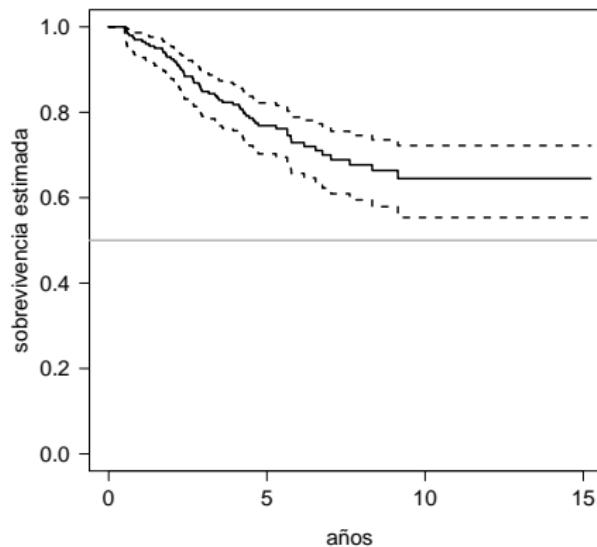
# Estimadores NP de la función de sobrevida

```
> thick.cat=ifelse(thick<1.94,0,1)  
> KM.thick=survfit(Surv(t1, d1) ~ thick.cat,  
> conf.type="log-log")  
> plot(KM.thick, ...)
```



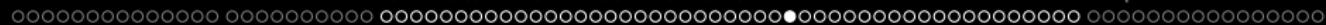
# Estimadores NP de la función de sobrevida

¿Cómo estimar la mediana (u otro percentil) usando el estimador de Kaplan-Meier?



Para este conjunto de datos no se puede estimar la mediana basándonos en el estimador de K-M.





## Estimadores NP de la función de sobrevivencia

```
> KM.0=survfit(Surv(t1, d1) ~ 1, conf.type="log-log")
> KM.0
```

```
Call: survfit(formula = Surv(t1, d1) ~ 1,
conf.type = "log-log")
```

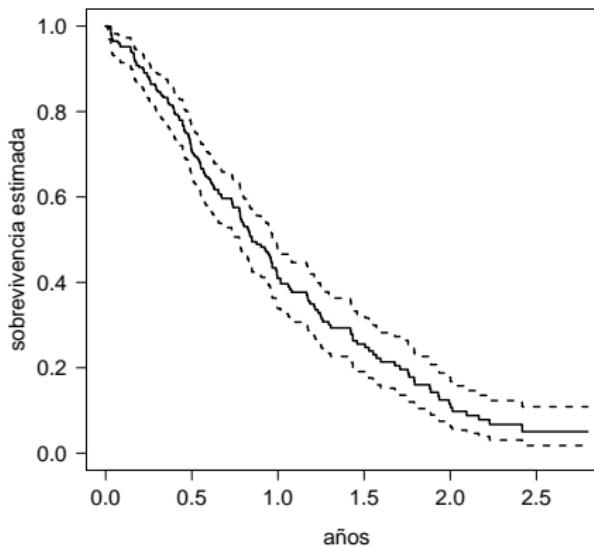
n	events	median	0.95LCL	0.95UCL
205	57	NA	NA	NA

Como  $\hat{S}_{KM}(t) > 0.5, \forall t > 0$ , entonces no se puede obtener una estimativa para la mediana basado en este estimador.



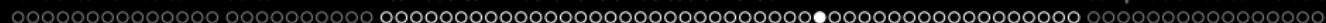
# Estimadores NP de la función de sobrevida

¿Cómo estimar la mediana (u otro percentil) usando el estimador de Kaplan-Meier?



(Conjunto de datos de cáncer de pulmón)





# Estimadores NP de la función de sobrevida

```
> KM.00=survfit(Surv(t2, d2) ~ 1,  
+ conf.type="log-log")  
> KM.00
```

```
Call: survfit(formula = Surv(t2, d2) ~ 1, conf.type = "log-log")
```

n	events	median	0.95LCL	0.95UCL
227	164.000	0.849	0.778	0.988





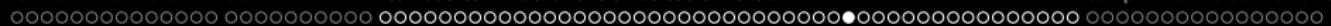
# Estimadores NP de la función de sobrevivencia

> summary(KM.00)

```
Call: survfit(formula = Surv(t2, d2) ~ 1, conf.type = "log-log")
```

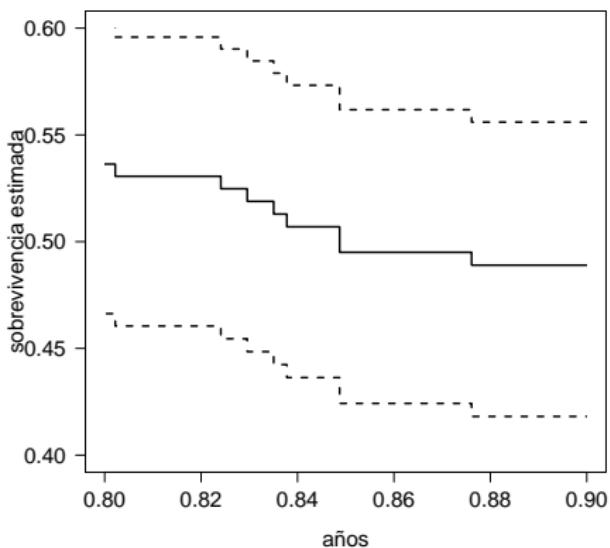
	time	n.risk	n.event	survival	std.err	lower	95% CI	upper	95% CI
0.0137	227		1	0.9956	0.00440		0.9691		0.999
0.0301	226		3	0.9824	0.00873		0.9537		0.993
0.0329	223		1	0.9780	0.00974		0.9479		0.991
...									
0.8350	87		1	0.5152	0.03504		0.4445		0.581
0.8378	86		1	0.5092	0.03514		0.4384		0.576
0.8487	85		2	0.4972	0.03532		0.4262		0.564
0.8761	82		1	0.4912	0.03541		0.4201		0.558
0.9008	81		1	0.4851	0.03548		0.4140		0.552
...									





# Estimadores NP de la función de sobrevida

¿Cómo estimar la mediana (u otro percentil) usando el estimador de Kaplan-Meier?

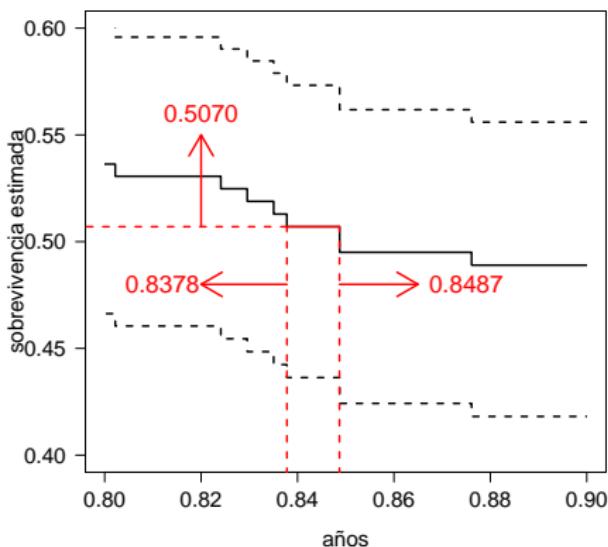


(Conjunto de datos de cáncer de pulmón)



# Estimadores NP de la función de sobrevida

¿Cómo estimar la mediana (u otro percentil) usando el estimador de Kaplan-Meier?

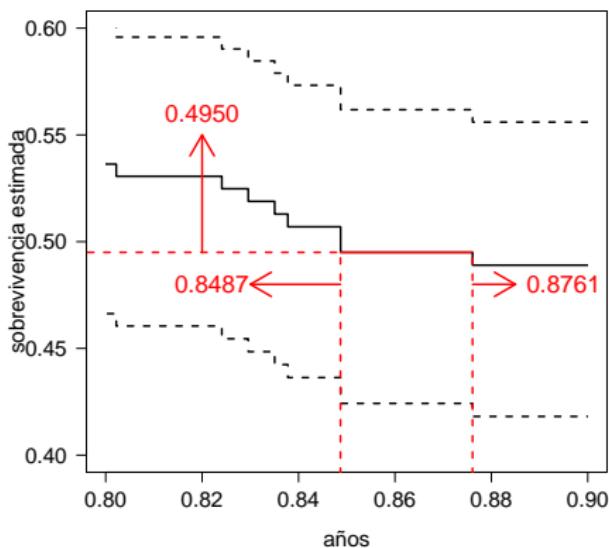


(Conjunto de datos de cáncer de pulmón)



# Estimadores NP de la función de sobrevida

¿Cómo estimar la mediana (u otro percentil) usando el estimador de Kaplan-Meier?

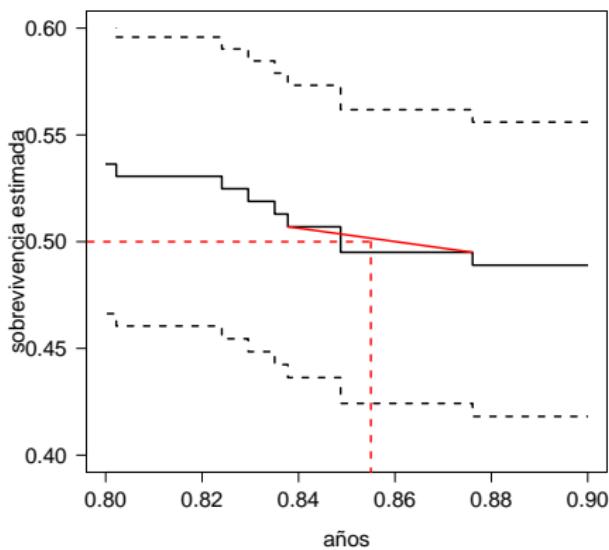


(Conjunto de datos de cáncer de pulmón)



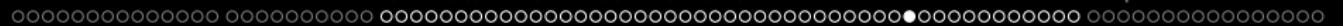
# Estimadores NP de la función de sobrevida

¿Cómo estimar la mediana (u otro percentil) usando el estimador de Kaplan-Meier?



Interpolación lineal entre los puntos  $(0.8378, 0.5070)$  y  $(0.8761, 0.4950)$ .

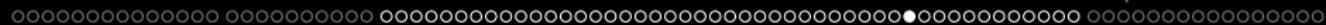




# Estimadores NP de la función de sobrevida

¿Cómo estimar la media usando el estimador de Kaplan-Meier?





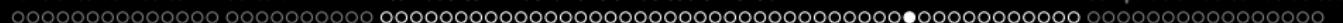
# Estimadores NP de la función de sobrevida

¿Cómo estimar la media usando el estimador de Kaplan-Meier?

Se puede chequear que, para cualquier distribución positiva en que la media exista, se tiene que

$$\begin{aligned}\mathbb{E}(T) &= \int_0^{+\infty} t \times f(t) dt \\ &= \int_0^{+\infty} S(t) dt.\end{aligned}$$





## Estimadores NP de la función de sobrevida

¿Cómo estimar la media usando el estimador de Kaplan-Meier?

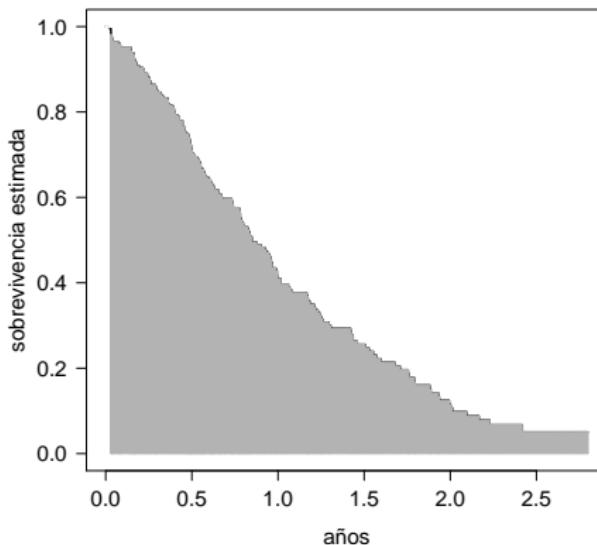
Se puede chequear que, para cualquier distribución positiva en que la media exista, se tiene que

$$\begin{aligned}\mathbb{E}(T) &= \int_0^{+\infty} t \times f(t) dt \\ &= \int_0^{+\infty} S(t) dt.\end{aligned}$$

En otras palabras, la media de la distribución es el área bajo la curva de sobrevida de la variable aleatoria T. (siempre y cuando ésta exista).



# Estimadores NP de la función de sobrevivencia



Ejemplo del área bajo la curva para el conjunto de datos de cáncer de pulmón.

Nota: Recuerde que si la observación más grande de la muestra es censurada, entonces  $\hat{S}_{KM}(t) > 0, \forall t > t_k$ .



# Estimadores NP de la función de sobrevivencia

De forma general, se puede chequear que, para cualquier distribución positiva se tiene que

$$\mathbb{E}(T^k) = \int_0^{+\infty} t^{k-1} S(t) dt.$$

Es decir,  $\mathbb{E}(T^k)$  es el área bajo la curva de la función  $t^{k-1}S(t)$ , siempre y cuando esa esperanza exista. De esta forma, una fórmula para la varianza puede ser deducida.

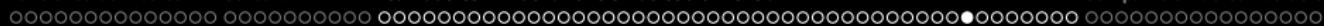


# Estimadores NP de la función de sobrevida

Tanto la media como la varianza estimada a través del estimador de Kaplan-Meier pueden ser obtenidas usando la función `enparCensored` del paquete EnvStats

```
enparCensored(x, censored, censoring.side = "left",
               correct.se = FALSE, left.censored.min = "DL",
               right.censored.max = "DL", ci = FALSE,
               ci.method = "normal.approx", ci.type = "two-sided",
               conf.level = 0.95, pivot.statistic = "z",
               ci.sample.size = NULL, n.bootstraps = 1000)
```





# Estimadores NP de la función de sobrevida

Tanto la media como la varianza estimada a través del estimador de Kaplan-Meier pueden ser obtenidas usando la función `enparCensored` del paquete EnvStats

```
enparCensored( x, censored, censoring.side = "left",
  correct.se = FALSE, left.censored.min = "DL",
  right.censored.max = "DL", ci = FALSE,
  ci.method = "normal.approx", ci.type = "two-sided",
  conf.level = 0.95, pivot.statistic = "z",
  ci.sample.size = NULL, n.bootstraps = 1000)
```

**x**: tiempos observados. **censored**: indicador de censura. **censoring.side**: censura a la izquierda (left) o a la derecha (right). **right.censored.max**: Valor de censura máximo DL (detection limit, detecta automáticamente la censura más alta); puede especificarse un valor.

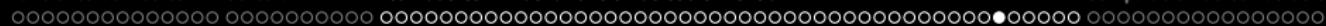




# Estimadores NP de la función de sobrevida

```
> enparCensored(t2, 1-d2, censoring.side = "right")
$distribution
[1] "None"
$sample.size
[1] 227
...
$percent.censored
[1] 27.7533
$parameters
      mean        sd    se.mean
1.03347528 0.72608416 0.05409535
$n.param.est
[1] 2
$method
[1] "Kaplan-Meier"
...
```





# Estimadores NP de la función de sobrevivencia

De esta forma, para el conjunto de datos de cáncer de pulmón tenemos que  $\widehat{\mathbb{E}(T)} = 1.0335$ ,  $\sqrt{\widehat{\text{Var}(T)}} = 0.7261$  y s.e.  $(\widehat{\mathbb{E}(T)}) = 0.0541$ .



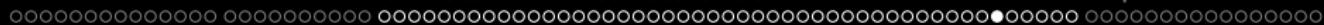


## Estimadores NP de la función de sobrevida

De esta forma, para el conjunto de datos de cáncer de pulmón tenemos que  $\widehat{\mathbb{E}(T)} = 1.0335$ ,  $\sqrt{\widehat{\text{Var}(T)}} = 0.7261$  y s.e.  $(\widehat{\mathbb{E}(T)}) = 0.0541$ .

Note que la media y desviación estándar usual de los tiempos (ignorando que son datos censurados a la derecha) son 0.8357 y 0.5767, respectivamente.





## Estimadores NP de la función de sobrevida

De esta forma, para el conjunto de datos de cáncer de pulmón tenemos que  $\widehat{\mathbb{E}(T)} = 1.0335$ ,  $\sqrt{\widehat{\text{Var}}(T)} = 0.7261$  y s.e.  $(\widehat{\mathbb{E}(T)}) = 0.0541$ .

Note que la media y desviación estándar usual de los tiempos (ignorando que son datos censurados a la derecha) son 0.8357 y 0.5767, respectivamente.

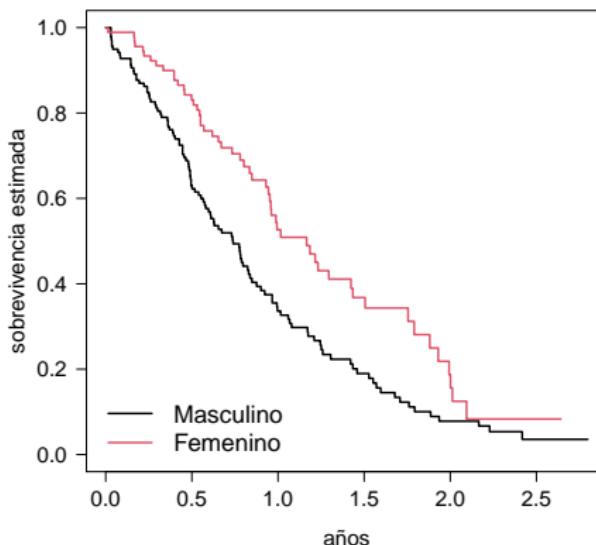
NOTA: En presencia de covariables, el mismo procedimiento podría ser aplicado para cada grupo, de forma de obtener estimaciones para la media y desviación estándar en cada factor de una covariable, o bien, en combinaciones de factores de covariables.



# Estimadores NP de la función de sobrevida

En el ejemplo de cáncer de pulmón.

```
KM.s.2=survfit(Surv(t2, d2) ~ sex2, conf.type="log-log")
plot(KM.s.2, ...)
```



# Estimadores NP de la función de sobrevivencia

> KM.s.2

```
Call: survfit(formula = Surv(t2, d2) ~ sex2, conf.type = "log-log")
```

	n	events	median	0.95LCL	0.95UCL
sex2=1	137	111	0.739	0.580	0.849
sex2=2	90	53	1.166	0.945	1.435



# Estimadores NP de la función de sobrevida

```
> hombres<-which(sex2==1)
> enparCensored(t2[hombres], 1-d2[hombres], censoring.side = "right")
$distribution
[1] "None"
$sample.size
[1] 137
...
$percent.censored
[1] 18.9781
$parameters
      mean        sd     se.mean
0.89718785 0.68364094 0.06303053
$n.param.est
[1] 2
$method
[1] "Kaplan-Meier"
...
```





# Estimadores NP de la función de sobrevida

```
> mujeres<-which(sex2==2)
> enparCensored(t2[mujeres], 1-d2[mujeres], censoring.side = "right")
$distribution
[1] "None"
$sample.size
[1] 90
...
$percent.censored
[1] 41.11111
$parameters
      mean        sd     se.mean
1.24819736 0.72382830 0.09012297
$n.param.est
[1] 2
$method
[1] "Kaplan-Meier"
...
```



# Estimadores NP de la función de sobrevida

En otras palabras,

	Hombres	Mujeres
$\widehat{\mathbb{E}(T)}$	0.8972	1.2482
$\sqrt{\widehat{\text{Var}(T)}}$	0.6836	0.7238
s.e. $(\widehat{\mathbb{E}(T)})$	0.0630	0.0901
$\widehat{Me(T)}$	0.7390	1.1660
<hr/>		
$\bar{t}$	0.7790	0.9280
$S_t$	0.5839	0.5571
me( $t$ )	0.6160	0.8008



## *Comparación de curvas de sobrevida*

# Comparación de curvas de sobrevida



# Comparación de curvas de sobrevida

Considere que queremos comparar las curvas de sobrevida en dos grupos, digamos 1 y 2. En otras palabras, queremos testear las hipótesis

$$H_0 : S_1(t) = S_2(t), \quad \forall t > 0 \quad \text{versus} \quad H_1 : \text{Lo contrario.}$$

Asumamos que  $t_1 < t_2 < \dots < t_k$  son los diferentes tiempos de falla observados al combinar todos los tiempos observados en ambos grupos.



# Comparación de curvas de sobrevida

En cada tiempo de falla  $t_j$ ,  $j = 1, \dots, k$ , podemos generar una tabla de contingencia como la siguiente

		Grupo	
		1	2
Fallas hasta $t_j$		$d_{1j}$	$d_{2j}$
No fallas hasta $t_j$		$n_{1j} - d_{1j}$	$n_{2j} - d_{2j}$
		$n_{1j}$	$n_{2j}$
		$n_j$	



# Comparación de curvas de sobrevida

En este contexto, el primer test propuesto fue el de *logrank* (Mantel, 1966), cuya estadística es dada por

$$T = \frac{\left[ \sum_{j=1}^k (d_{2j} - w_{2j}) \right]^2}{\sum_{j=1}^k (V_j)_2},$$

en que  $w_{2j} = n_{2j}d_j/n_j$  y  $(V_j)_2 = n_{2j}n_{1j}d_j(n_j - d_j)/(n_j^2(n_j - 1)^2)$ .

Sobre  $H_0$ ,  $T \sim \chi^2_{(1)}$ .



# Comparación de curvas de sobrevida

En este contexto, el primer test propuesto fue el de *logrank* (Mantel, 1966), cuya estadística es dada por

$$T = \frac{\left[ \sum_{j=1}^k (d_{2j} - w_{2j}) \right]^2}{\sum_{j=1}^k (V_j)_2},$$

en que  $w_{2j} = n_{2j}d_j/n_j$  y  $(V_j)_2 = n_{2j}n_{1j}d_j(n_j - d_j)/(n_j^2(n_j - 1)^2)$ .

Sobre  $H_0$ ,  $T \sim \chi^2_{(1)}$ .

NOTA: es recomendable usar este test si se satisface que el cuociente de las funciones de riesgo de ambos grupos es aproximadamente constante (i.e., propiedad de riesgos proporcionales).



# Comparación de curvas de sobrevida

Otras propuestas en la literatura:

$$T = \frac{\left[ \sum_{j=1}^k u_j (d_{2j} - w_{2j}) \right]^2}{\sum_{j=1}^k u_j^2 (V_j)_2},$$

en que  $u_j$ ,  $j = 1, \dots, k$  son pesos asociados a las tablas de contingencia de cada uno de los tiempos de falla. Casos particulares:



# Comparación de curvas de sobrevida

Otras propuestas en la literatura:

$$T = \frac{\left[ \sum_{j=1}^k u_j (d_{2j} - w_{2j}) \right]^2}{\sum_{j=1}^k u_j^2 (V_j)_2},$$

en que  $u_j$ ,  $j = 1, \dots, k$  son pesos asociados a las tablas de contingencia de cada uno de los tiempos de falla. Casos particulares:

- $u_j = 1$ : test de logrank.



# Comparación de curvas de sobrevida

Otras propuestas en la literatura:

$$T = \frac{\left[ \sum_{j=1}^k u_j (d_{2j} - w_{2j}) \right]^2}{\sum_{j=1}^k u_j^2 (V_j)_2},$$

en que  $u_j$ ,  $j = 1, \dots, k$  son pesos asociados a las tablas de contingencia de cada uno de los tiempos de falla. Casos particulares:

- $u_j = 1$ : test de logrank.
- $u_j = n_j$ : test de Gehan-Breslow (Gehan, 1965; Breslow, 1970).



# Comparación de curvas de sobrevida

Otras propuestas en la literatura:

$$T = \frac{\left[ \sum_{j=1}^k u_j (d_{2j} - w_{2j}) \right]^2}{\sum_{j=1}^k u_j^2 (V_j)_2},$$

en que  $u_j$ ,  $j = 1, \dots, k$  son pesos asociados a las tablas de contingencia de cada uno de los tiempos de falla. Casos particulares:

- $u_j = 1$ : test de logrank.
- $u_j = n_j$ : test de Gehan-Breslow (Gehan, 1965; Breslow, 1970).
- $u_j = \sqrt{n_j}$ : test de Tarone and Ware (1977).



# Comparación de curvas de sobrevida

Otras propuestas en la literatura:

$$T = \frac{\left[ \sum_{j=1}^k u_j (d_{2j} - w_{2j}) \right]^2}{\sum_{j=1}^k u_j^2 (V_j)_2},$$

en que  $u_j$ ,  $j = 1, \dots, k$  son pesos asociados a las tablas de contingencia de cada uno de los tiempos de falla. Casos particulares:

- $u_j = 1$ : test de logrank.
- $u_j = n_j$ : test de Gehan-Breslow (Gehan, 1965; Breslow, 1970).
- $u_j = \sqrt{n_j}$ : test de Tarone and Ware (1977).
- $u_j = \tilde{S}(t_{j-1})n_j/(n_j + 1)$ : test de Peto-Peto (1972); Prentice and Marek (1979), con  $\tilde{S}(t) = \prod_{j:t_j < t} \left( \frac{n_j + 1 - d_j}{n_j + 1} \right)$ .



# Comparación de curvas de sobrevida

Otras propuestas en la literatura:

$$T = \frac{\left[ \sum_{j=1}^k u_j (d_{2j} - w_{2j}) \right]^2}{\sum_{j=1}^k u_j^2 (V_j)_2},$$

en que  $u_j$ ,  $j = 1, \dots, k$  son pesos asociados a las tablas de contingencia de cada uno de los tiempos de falla. Casos particulares:

- $u_j = 1$ : test de logrank.
- $u_j = n_j$ : test de Gehan-Breslow (Gehan, 1965; Breslow, 1970).
- $u_j = \sqrt{n_j}$ : test de Tarone and Ware (1977).
- $u_j = \tilde{S}(t_{j-1})n_j/(n_j + 1)$ : test de Peto-Peto (1972); Prentice and Marek (1979), con  $\tilde{S}(t) = \prod_{j:t_j < t} \left( \frac{n_j+1-d_j}{n_j+1} \right)$ .
- $u_j = [\hat{S}_{KM}(t_{j-1})]^\rho$ : test de Harrington-Fleming (1982).



# Comparación de curvas de sobrevida

La función `logrank_test` del paquete `coin` permite implementar estos tests

```
logrank_test(formula, ties.method = c("mid-ranks", "Hothorn-Lausen",
                                         "average-scores"),
             type = c("logrank", "Gehan-Breslow", "Tarone-Ware", "Prentice",
                     "Prentice-Marek", "Andersen-Borgan-Gill-Keiding",
                     "Fleming-Harrington", "Gaugler-Kim-Liao", "Self"),
             rho = NULL, gamma = NULL, ...)
```



# Comparación de curvas de sobrevida

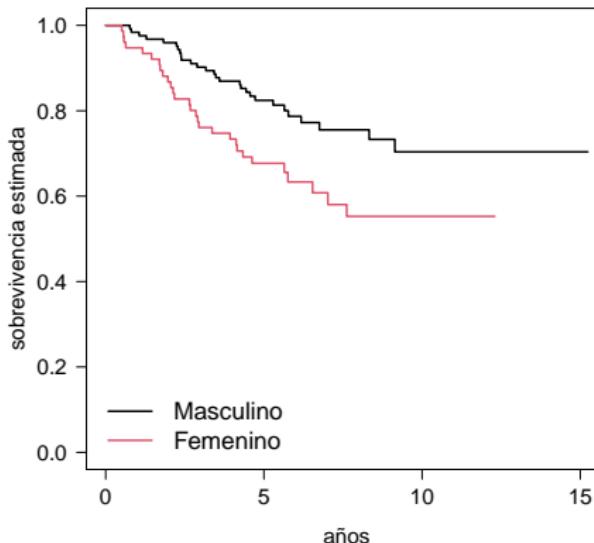
La función `logrank_test` del paquete `coin` permite implementar estos tests

```
logrank_test(formula, ties.method = c("mid-ranks", "Hothorn-Lausen",
                                         "average-scores"),
             type = c("logrank", "Gehan-Breslow", "Tarone-Ware", "Prentice",
                     "Prentice-Marek", "Andersen-Borgan-Gill-Keiding",
                     "Fleming-Harrington", "Gaugler-Kim-Liao", "Self"),
             rho = NULL, gamma = NULL, ...)
```

# Estimadores NP de la función de sobrevida

Volvamos a nuestro ejemplo del cáncer de melanoma...

```
> KM.sex=survfit(Surv(t1, d1) ~ sex1)  
> plot(KM.sex, ...)
```





# Estimadores NP de la función de sobrevida

Por ejemplo, para hacer el test de log-rank para comparar las curvas de sobrevida por sexo usamos

```
> logrank_test(Surv(t1, d1) ~ as.factor(sex1))
```

Asymptotic Two-Sample Logrank Test

```
data: Surv(t1, d1) by as.factor(sex1) (0, 1)
Z = 2.4917, p-value = 0.01271
alternative hypothesis: true theta is not equal to 1
```





## Estimadores NP de la función de sobrevida

Análogamente, para hacer el test de Tarone and Ware para comparar las curvas de sobrevida por sexo usamos

```
> logrank_test(Surv(t1, d1) ~ as.factor(sex1),  
                 type="Tarone-Ware")
```

Asymptotic Two-Sample Tarone-Ware Test

```
data: Surv(t1, d1) by as.factor(sex1) (0, 1)  
Z = 2.6169, p-value = 0.008873  
alternative hypothesis: true theta is not equal to 1
```





## Estimadores NP de la función de sobrevida

Análogamente, para hacer el test de Fleming and Harrington (con  $\rho = 0.5$ ) para comparar las curvas de sobrevida por sexo usamos

```
> logrank_test(Surv(t1, d1) ~ as.factor(sex1),  
type = "Fleming-Harrington", rho=0.5)
```

Asymptotic Two-Sample Fleming-Harrington Test

```
data: Surv(t1, d1) by as.factor(sex1) (0, 1)  
Z = 2.5559, p-value = 0.01059  
alternative hypothesis: true theta is not equal to 1
```



# Estimadores NP de la función de sobrevida

Un resumen de los 5 tests se muestra a continuación

Test	Z	p-value
log-rank	2.4917	0.012710
Gehan-Breslow	2.6743	0.007489
Tarone-Ware	2.6169	0.008873
Prentice-Marek	2.6144	0.008939
Fleming-Harrington	2.5559	0.010590

Note que todos los tests rechazan la hipótesis de igualdad usando un 5% de significación, mientras que si se usa un 1% de significación los tests de log-rank y de Fleming-Harrington no rechazan la hipótesis nula.

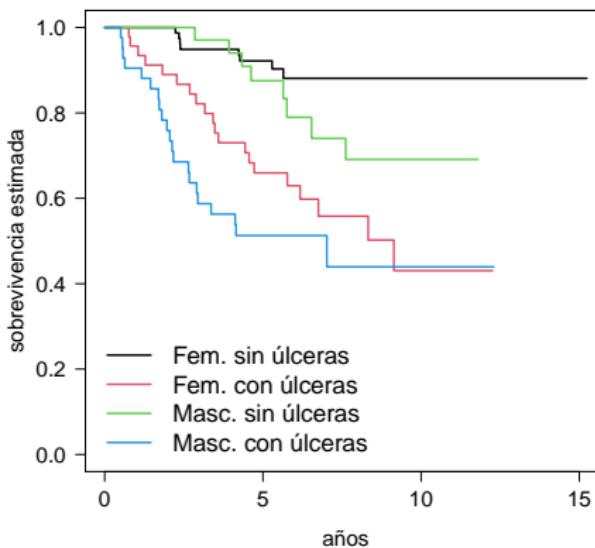




# Estimadores NP de la función de sobrevida

Observación: el test también permite la comparación de 3 o más grupos.

```
KM.su=survfit(Surv(t1, d1) ~ sex1 + ulc,  
conf.type="log-log")  
plot(KM.su, ...)
```





# Estimadores NP de la función de sobrevida

Podemos crear una nueva variable indicando cada uno de los grupos

```
> grupos=rep(NA, length=length(sex1))
> for(i in 1:length(sex1))
+ {
+   if(sex1[i]==0 & ulc[i]==0) grupos[i]=1
+   if(sex1[i]==0 & ulc[i]==1) grupos[i]=2
+   if(sex1[i]==1 & ulc[i]==0) grupos[i]=3
+   if(sex1[i]==1 & ulc[i]==1) grupos[i]=4
+ }
> table(grupos)
```

grupos

1	2	3	4
79	47	36	43



# Estimadores NP de la función de sobre vivencia

Así, para hacer el test de log-rank para comparar las curvas de  
sobrevivencia por sexo y úlceras usamos

```
> logrank_test(Surv(t1, d1) ~ as.factor(grupos))
```

Asymptotic K-Sample Logrank Test

```
data: Surv(t1, d1) by as.factor(grupos) (1, 2, 3, 4)
chi-squared = 30.63, df = 3, p-value = 1.017e-06
```



# Estimadores NP de la función de supervivencia

Un resumen de los 5 tests para este caso se muestra a continuación

Test	$\chi^2$	p-value
log-rank	30.630	1.017e-06
Gehan-Breslow	33.971	2.009e-07
Tarone-Ware	32.617	3.879e-07
Prentice-Marek	32.720	3.689e-07
Fleming-Harrington	31.710	6.025e-07

Note que todos los tests rechazan la hipótesis de igualdad usando cualquier nivel de significación usual.



## *Modelos paramétricos*

# Modelos paramétricos



## *Modelos paramétricos*

# Distribución Weibull



# Modelos paramétricos

- Distribución Weibull

$$f(t; \theta) = \frac{\gamma}{\alpha^\gamma} t^{\gamma-1} \exp \left\{ - \left( \frac{t}{\alpha} \right)^\gamma \right\},$$

$$S(t; \theta) = \exp \left\{ - \left( \frac{t}{\alpha} \right)^\gamma \right\},$$

$$\Lambda(t; \theta) = \left( \frac{t}{\alpha} \right)^\gamma, \quad t, \alpha, \gamma > 0,$$

en que  $\theta = (\gamma, \alpha)$ . Denotaremos como WEI( $\gamma, \alpha$ )



# Modelos paramétricos

- Distribución Weibull

$$f(t; \theta) = \frac{\gamma}{\alpha^\gamma} t^{\gamma-1} \exp\left\{-\left(\frac{t}{\alpha}\right)^\gamma\right\},$$

$$S(t; \theta) = \exp\left\{-\left(\frac{t}{\alpha}\right)^\gamma\right\},$$

$$\Lambda(t; \theta) = \left(\frac{t}{\alpha}\right)^\gamma, \quad t, \alpha, \gamma > 0,$$

en que  $\theta = (\gamma, \alpha)$ . Denotaremos como WEI( $\gamma, \alpha$ )

- $\gamma = 1$ : modelo exponencial.
- $\alpha$  es un parámetro de escala y  $\gamma$  es un parámetro de forma.
- Función de riesgo es monótona: puede ser constante ( $\gamma = 1$ ), decreciente ( $\gamma < 1$ ) o creciente ( $\gamma > 1$ ).



# Modelos paramétricos

Si  $T \sim \text{WEI}(\gamma, \alpha)$

- $\mathbb{E}(T) = \alpha\Gamma(1 + 1/\gamma);$
- $\text{Var}(T) = \alpha^2 [\Gamma(1 + 2/\gamma) - \{\Gamma(1 + 1/\gamma)\}^2];$
- $t_q = \alpha[-\log(1 - q)]^{1/\gamma}$  es el percentil  $100 \times q$  de la distribución, con  $q \in (0, 1)$ ,

siendo  $\Gamma(\cdot)$  la función gamma.



# Modelos paramétricos

Además si  $T \sim \text{WEI}(\gamma, \alpha)$ , entonces  $Y = \log(T) \sim VE(\mu, \sigma)$   
 (distribución valor extremo)

$$f(y; \mu, \sigma) = \frac{1}{\sigma} \exp \left\{ \left( \frac{y - \mu}{\sigma} \right) - \exp \left\{ \frac{y - \mu}{\sigma} \right\} \right\},$$

$$S(y; \mu, \sigma) = \exp \left\{ - \exp \left\{ \frac{y - \mu}{\sigma} \right\} \right\}, \quad y, \mu \in \mathbb{R}, \sigma > 0,$$

en que  $\mu = \log(\alpha)$  y  $\sigma = 1/\gamma$  son parámetros de localización y escala, respectivamente.



## Modelos paramétricos

En R, para el modelo Weibull las siguientes funciones estás implementadas en el paquete base de R

```
> dweibull(x, shape, scale=1, log=FALSE)
> pweibull(x, shape, scale=1, lower.tail = TRUE, log.p = FALSE)
> qweibull(x, shape, scale=1, lower.tail = TRUE, log.p = FALSE)
> rweibull(n, shape, scale=1)
```

que corresponden a la función de densidad (**dweibull**), distribución acumulada (**pweibull**), cuantil (**qweibull**) y un generador de números aleatorios (**rweibull**), respectivamente.



# Modelos paramétricos

La función de distribución acumulada de  $T \sim \text{WEI}(\gamma = 1.3, \alpha = 10)$ , evaluada en los tiempos 1, 3 y 5, puede ser calculada como

```
> pweibull(c(1,3,5), shape=1.3, scale=10)
[1] 0.0488835 0.1886482 0.3337739
```



## *Modelos paramétricos*

La función de distribución acumulada de  $T \sim \text{WEI}(\gamma = 1.3, \alpha = 10)$ , evaluada en los tiempos 1, 3 y 5, puede ser calculada como

```
> pweibull(c(1,3,5), shape=1.3, scale=10)
[1] 0.0488835 0.1886482 0.3337739
```

Mientras que la función de sobrevivencia de la misma variable aleatoria evaluada en los mismos puntos se calcula como

```
> pweibull(c(1,3,5), shape=1.3, scale=10, lower.tail=FALSE)
[1] 0.9511165 0.8113518 0.6662261
```



## Modelos paramétricos

La función de riesgo y de riesgo acumulada no están implementadas en R, pero en base a las funciones anteriores de pueden implementar fácilmente

```
> hweibull<-function(x, shape, scale=1)
{
  exp(dweibull(x, shape, scale=1, log=TRUE) -
      pweibull(x, shape, scale=1, log=TRUE))
}

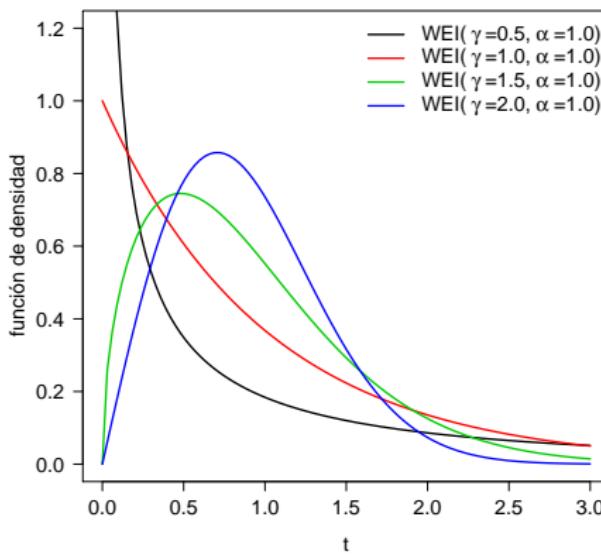
> Hweibull<-function(x, shape, scale=1)
{-pweibull(x, shape, scale, lower.tail=FALSE, log=TRUE)}
```



# Modelos paramétricos

Para graficar la función de densidad del modelo WEI, basta usar

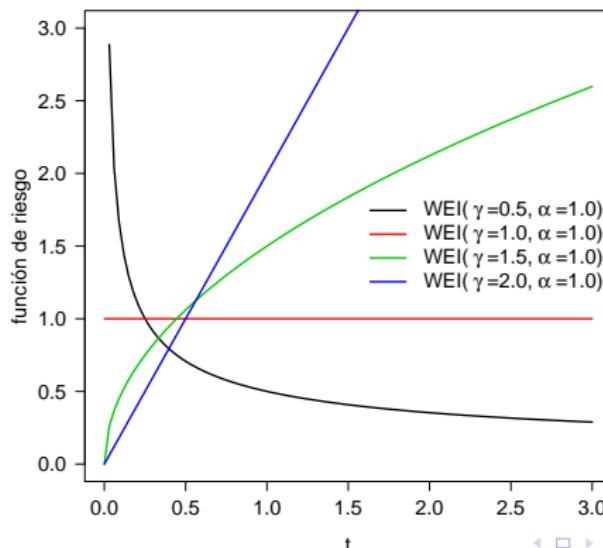
```
> curve(dweibull(x, shape=0.5, scale=1.0),...)
```



## Modelos paramétricos

Análogamente, para graficar la función de riesgo del modelo WEI, basta usar

```
curve(hweibull(x, shape=0.5, scale=1.0),...)
```



## Modelos paramétricos

# Distribución log-normal



# Modelos paramétricos

- Distribución log-normal

$$f(t; \theta) = \frac{1}{\sqrt{2\pi} t \sigma} \exp \left\{ -\frac{1}{2} \left( \frac{\log(t) - \mu}{\sigma} \right)^2 \right\},$$

$$S(t; \theta) = 1 - \Phi \left( \frac{\log(t) - \mu}{\sigma} \right),$$

$$\lambda(t; \theta) = \frac{f(t; \theta)}{S(t; \theta)}, \quad t, \sigma > 0, \mu \in \mathbb{R}$$

en que  $\theta = (\mu, \sigma)$ .

- $\sigma$  es un parámetro de escala y  $\mu$  es un parámetro de localización.
- Función de riesgo es no monótona: es creciente hasta alcanzar un valor máximo y luego es decreciente.
- $Y = \log(T) \sim N(\mu, \sigma^2)$ .



# Modelos paramétricos

Si  $T \sim \text{LN}(\mu, \sigma)$

- $\mathbb{E}(T) = \exp(\mu + \sigma^2/2);$
- $\text{Var}(T) = \exp(2\mu + \sigma^2)(\exp(\sigma^2) - 1);$
- $t_q = \exp(\mu + z_q\sigma)$  es el percentil  $100 \times q$  de la distribución, con  $q \in (0, 1)$ .



## Modelos paramétricos

En R, para el modelo LN las siguientes funciones estás implementadas en el paquete base de R

```
> dlnorm(x, meanlog = 0, sdlog = 1, log = FALSE)  
> plnorm(q, meanlog = 0, sdlog = 1, lower.tail = TRUE, log.p = FALSE)  
> qlnorm(p, meanlog = 0, sdlog = 1, lower.tail = TRUE, log.p = FALSE)  
> rlnorm(n, meanlog = 0, sdlog = 1)
```

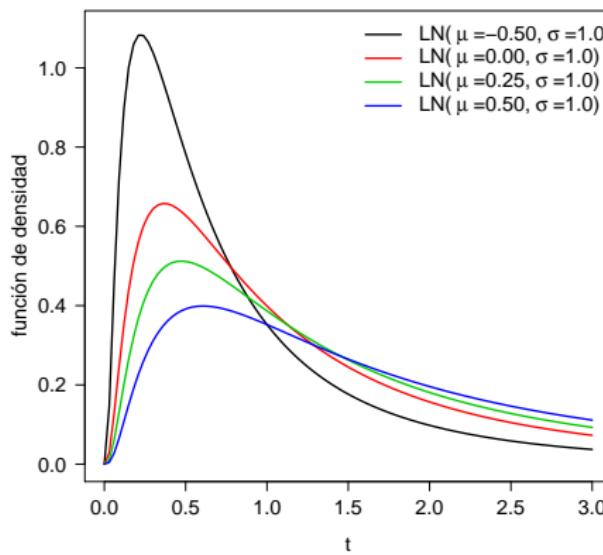
que corresponden a la función de densidad (`dlnorm`), distribución acumulada (`plnorm`), cuantil (`qlnorm`) y un generador de números aleatorios (`rlnorm`), respectivamente.



## Modelos paramétricos

Para graficar la función de densidad del modelo LN, basta usar

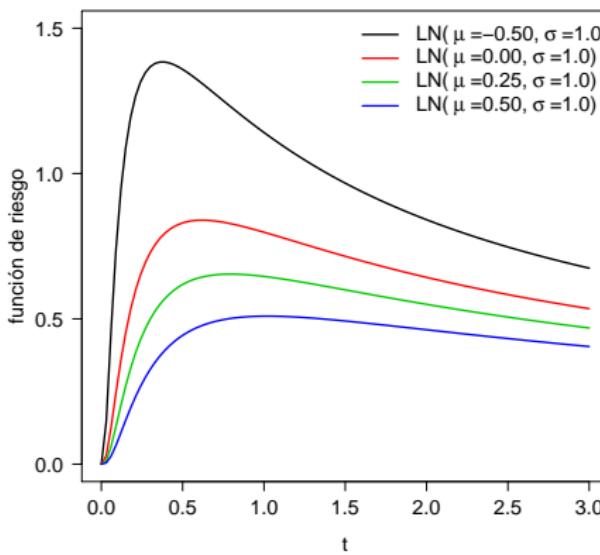
```
> curve(dlnorm(x, meanlog=-0.5, sdlog=1.0),...)
```



## Modelos paramétricos

Para graficar la función de densidad del modelo LN, basta usar

```
> curve(hlnorm(x, meanlog=-0.5, sdlog=1.0),...)
```



## Modelos paramétricos

# Distribución log-logística



# Modelos paramétricos

- Distribución log-logística

$$f(t; \theta) = \frac{\gamma}{\alpha^\gamma} t^{\gamma-1} \left(1 + \left(\frac{t}{\alpha}\right)^\gamma\right)^{-2},$$

$$S(t; \theta) = \frac{1}{1 + (t/\alpha)^\gamma},$$

$$\lambda(t; \theta) = \frac{\gamma(t/\alpha)^{\gamma-1}}{\alpha [1 + (t/\alpha)^\gamma]}, \quad t, \gamma, \alpha > 0.$$

en que  $\theta = (\alpha, \gamma)$ . Denotaremos como  $\text{LL}(\gamma, \alpha)$ .

- $\alpha$  es un parámetro de escala y  $\gamma$  es un parámetro de forma.
- Función de riesgo es no monótona para  $\gamma > 1$ : es creciente hasta alcanzar un valor máximo y luego es decreciente; monótona decreciente para  $\gamma \leq 1$ .



# Modelos paramétricos

Si  $T \sim \text{LL}(\gamma, \alpha)$

- $\mathbb{E}(T) = \frac{\pi\alpha}{\gamma \sin(\pi/\gamma)}$ ;
- $\text{Var}(T) = \frac{2\pi\alpha^2}{\gamma \sin(2\pi/\gamma)} - \mathbb{E}^2(T)$ ;
- $t_q = \alpha \left[ \frac{q}{1-q} \right]^{1/\gamma}$  es el percentil  $100 \times q$  de la distribución, con  $q \in (0, 1)$ .



## Modelos paramétricos

Si  $T \sim LL(\gamma, \alpha)$ , entonces  $Y = \log(T) \sim L(\mu, \sigma)$  (distribución logística)

$$f(y; \mu, \sigma) = \frac{1}{\sigma} \exp \left\{ \frac{y - \mu}{\sigma} \right\} \left( 1 + \exp \left\{ \frac{y - \mu}{\sigma} \right\} \right)^{-2},$$
$$S(y; \mu, \sigma) = \left( 1 + \exp \left\{ \frac{y - \mu}{\sigma} \right\} \right)^{-1}, \quad y, \mu \in \mathbb{R}, \sigma > 0,$$

en que  $\mu = \log(\alpha)$  y  $\sigma = 1/\gamma$  son parámetros de localización y escala, respectivamente.



## Modelos paramétricos

En R, para el modelo LL las siguientes funciones estás implementadas en el paquete actuar de R

```
> dlllogis(x, shape, rate = 1, scale = 1/rate, log = FALSE)
> pllogis(q, shape, rate = 1, scale = 1/rate, lower.tail = TRUE, log.p = FALSE)
> qllogis(p, shape, rate = 1, scale = 1/rate, lower.tail = TRUE, log.p = FALSE)
> rllogis(n, shape, rate = 1, scale = 1/rate)
```

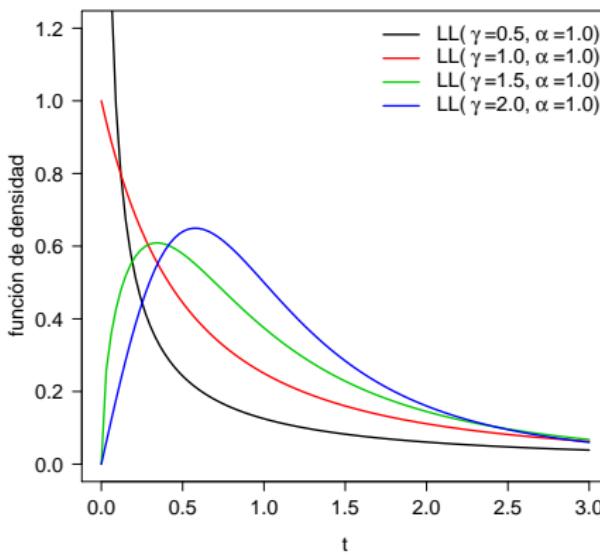
que corresponden a la función de densidad (**dlllogis**), distribución acumulada (**pllogis**), cuantil (**qllogis**) y un generador de números aleatorios (**rllogis**), respectivamente.



## Modelos paramétricos

Para graficar la función de densidad del modelo LN, basta usar

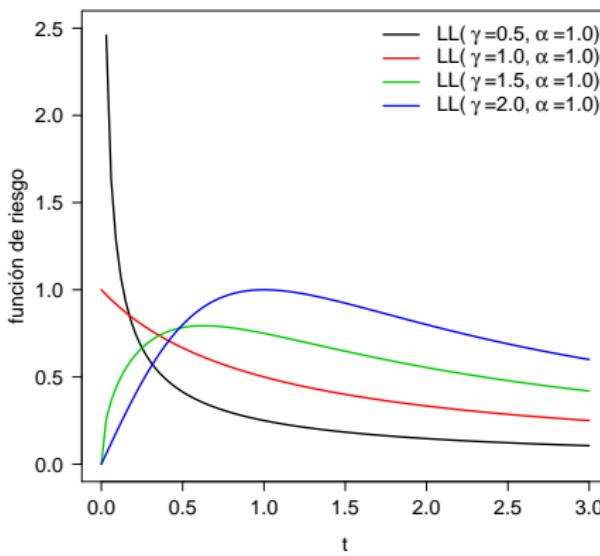
```
> curve(dllogis(x, shape=0.5, scale=1.0), ...)
```



# Modelos paramétricos

Para graficar la función de densidad del modelo LN, basta usar

```
> curve(hllogis(x, shape=0.5, scale=1.0),...)
```



## Modelos paramétricos

¿Cómo decidir qué modelo usar? (Antes de ajustarlo)



# Modelos paramétricos

Note que para el modelo WEI( $\gamma, \alpha$ ), tenemos que

$$S(t; \theta) = \exp \left\{ - \left( \frac{t}{\alpha} \right)^\gamma \right\}.$$

Es decir,

$$\begin{aligned} \log(-\log S(t; \theta)) &= \gamma(\log t - \log \alpha) \\ &= b_0^* + b_1^* \log t, \end{aligned}$$

en que  $b_0^* = -\gamma \log \alpha$  y  $b_1^* = \gamma$ .



# Modelos paramétricos

Note que para el modelo  $WEI(\gamma, \alpha)$ , tenemos que

$$S(t; \theta) = \exp \left\{ - \left( \frac{t}{\alpha} \right)^{\gamma} \right\}.$$

Es decir,

$$\begin{aligned} \log(-\log S(t; \theta)) &= \gamma (\log t - \log \alpha) \\ &= b_0^* + b_1^* \log t, \end{aligned}$$

en que  $b_0^* = -\gamma \log \alpha$  y  $b_1^* = \gamma$ . Por lo tanto, en poblaciones homogéneas, se sugiere construir el gráfico de  $\log t$  versus  $\log(-\log(\widehat{S}_{KM}(t)))$ . Si los puntos de ese gráfico se aproximan de una recta, entonces el modelo Weibull es apropiado para esos datos.



# Modelos paramétricos

Para el modelo  $\text{LN}(\mu, \sigma)$ , tenemos que

$$S(t; \theta) = 1 - \Phi\left(\frac{\log(t) - \mu}{\sigma}\right) = \Phi\left(-\frac{\log(t) - \mu}{\sigma}\right).$$

Es decir,

$$\begin{aligned}\Phi^{-1}(S(t; \theta)) &= -\frac{(\log(t) - \mu)}{\sigma} \\ &= b_0^* + b_1^* \log t,\end{aligned}$$

en que  $b_0^* = \mu/\sigma$  y  $b_1^* = -1/\sigma$ .



# Modelos paramétricos

Para el modelo  $\text{LN}(\mu, \sigma)$ , tenemos que

$$S(t; \theta) = 1 - \Phi\left(\frac{\log(t) - \mu}{\sigma}\right) = \Phi\left(-\frac{\log(t) - \mu}{\sigma}\right).$$

Es decir,

$$\begin{aligned}\Phi^{-1}(S(t; \theta)) &= -\frac{(\log(t) - \mu)}{\sigma} \\ &= b_0^* + b_1^* \log t,\end{aligned}$$

en que  $b_0^* = \mu/\sigma$  y  $b_1^* = -1/\sigma$ . Por lo tanto, en poblaciones homogéneas, se sugiere construir el gráfico de  $\log t$  versus  $\Phi^{-1}(\widehat{S}_{KM}(t))$ . Si los puntos de ese gráfico se aproximan de una recta, entonces el modelo log-normal es apropiado para esos datos.



# Modelos paramétricos

Finalmente, para el modelo  $\text{LL}(\gamma, \alpha)$ , tenemos que

$$S(t; \theta) = \frac{1}{1 + (t/\alpha)^\gamma}.$$

Es decir,

$$\begin{aligned}\log\left(\frac{1}{S(t; \theta)} - 1\right) &= \gamma(\log t - \log \alpha) \\ &= b_0^* + b_1^* \log t,\end{aligned}$$

en que  $b_0^* = -\gamma \log(\alpha)$  y  $b_1^* = \gamma$ .



# Modelos paramétricos

Finalmente, para el modelo  $LL(\gamma, \alpha)$ , tenemos que

$$S(t; \theta) = \frac{1}{1 + (t/\alpha)^\gamma}.$$

Es decir,

$$\begin{aligned}\log\left(\frac{1}{S(t; \theta)} - 1\right) &= \gamma(\log t - \log \alpha) \\ &= b_0^* + b_1^* \log t,\end{aligned}$$

en que  $b_0^* = -\gamma \log(\alpha)$  y  $b_1^* = \gamma$ . Por lo tanto, en poblaciones homogéneas, se sugiere construir el gráfico de  $\log t$  versus  $\log\left(\frac{1}{S_{KM}(t)} - 1\right)$ . Si los puntos de ese gráfico se aproximan de una recta, entonces el modelo log-logístico es apropiado para esos datos.



# Modelos paramétricos

Para el ejemplo de cáncer de pulmón tenemos que

```
##Calcula el estimador de KM  
> KM.0=survfit(Surv(t2, d2) ~ 1, conf.type="log-log")
```



## Modelos paramétricos

Para el ejemplo de cáncer de pulmón tenemos que

```
##Calcula el estimador de KM  
> KM.0=survfit(Surv(t2, d2) ~ 1, conf.type="log-log")  
  
##Captura los valores de los tiempos de falla  
> t0=KM.0$time[which(KM.0$surv>0 & KM.0$surv<1)]
```



# Modelos paramétricos

Para el ejemplo de cáncer de pulmón tenemos que

```
##Calcula el estimador de KM  
> KM.0=survfit(Surv(t2, d2) ~ 1, conf.type="log-log")  
  
##Captura los valores de los tiempos de falla  
> t0=KM.0$time[which(KM.0$surv>0 & KM.0$surv<1)]  
  
##Captura la sobrevida evaluada en los tiempos de falla  
> S0=KM.0$surv[which(KM.0$surv>0 & KM.0$surv<1)]
```



## Modelos paramétricos

Para el ejemplo de cáncer de pulmón tenemos que

```
##Calcula el estimador de KM
> KM.0=survfit(Surv(t2, d2) ~ 1, conf.type="log-log")

##Captura los valores de los tiempos de falla
> t0=KM.0$time[which(KM.0$surv>0 & KM.0$surv<1)]

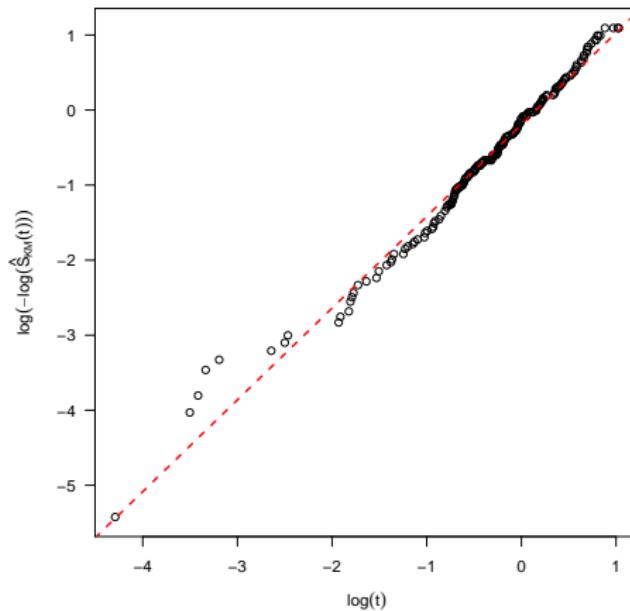
##Captura la sobrevida evaluada en los tiempos de falla
> S0=KM.0$surv[which(KM.0$surv>0 & KM.0$surv<1)]

##Hacemos un modelo de regresión entre log(-log(S0)) y log(t0)
> m.w<-lm(log(-log(S0))~log(t0))
```



# Modelos paramétricos

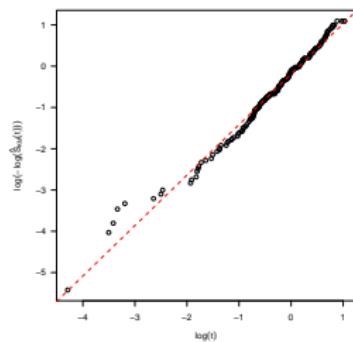
```
> plot(log(t0), log(-log(S0)), ...)  
> abline(coef(m.w)[1],coef(m.w)[2], ...)
```



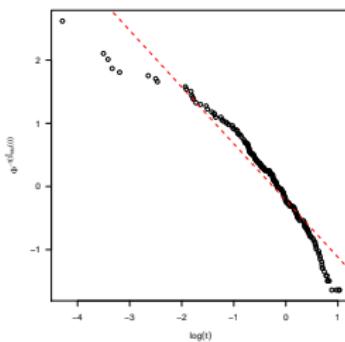
$$R_a^2 = 0.984$$

# Modelos paramétricos

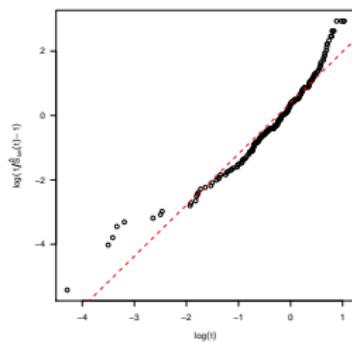
Para el conjunto de datos cáncer de pulmón (sin considerar covariables)



WEI ( $R_a^2 = 0.984$ )



LN ( $R_a^2 = 0.913$ )



LL ( $R_a^2 = 0.934$ )



# Modelos paramétricos

¿Y si tengo covariables?



## *Modelos paramétricos*

¿Y si tengo covariables?

Repita el proceso anterior para cada factor de la(s) covariable(s).





# Modelos paramétricos

```
> hombres<-which(sex2==0); mujeres<-which(sex2==1)
> KM.h=survfit(Surv(t2[hombres], d2[hombres]) ~ sex2[hombres])
> KM.m=survfit(Surv(t2[mujeres], d2[mujeres]) ~ sex2[mujeres])

> th<-summary(KM.h)$time; Sh<-summary(KM.h)$surv
> tm<-summary(KM.m)$time; Sm<-summary(KM.m)$surv

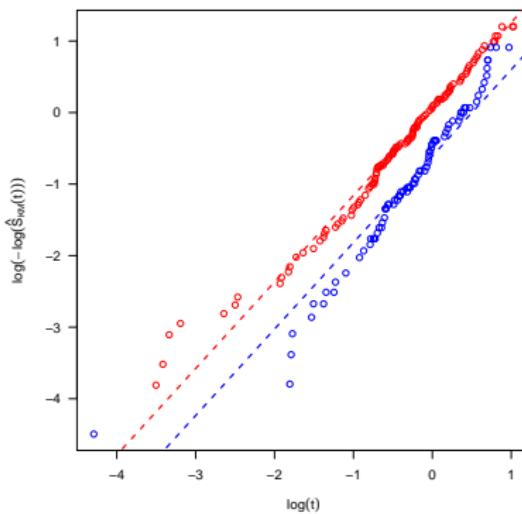
> t0<-c(th,tm); S0<-c(Sh,Sm); sex.f<-c(rep(0,length(th)),rep(1,length(tm)))
> m.w<-lm(log(-log(S0))~log(t0)+sex.f)
```





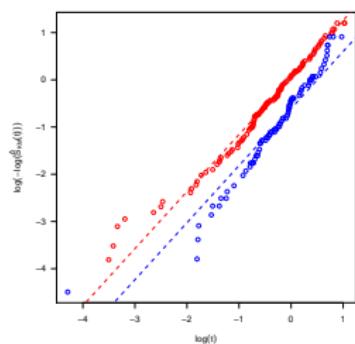
# Modelos paramétricos

```
> plot(log(t0), log(-log(S0)), ...)  
> points(log(th), log(-log(Sh)), ...)  
> abline(coef(m.w)[1],coef(m.w)[2], ...)  
> points(log(tm), log(-log(Sm)), ...)  
> abline(coef(m.w)[1]+coef(m.w)[3], coef(m.w)[2], ...)
```

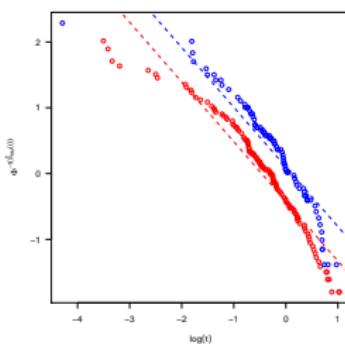


# Modelos paramétricos

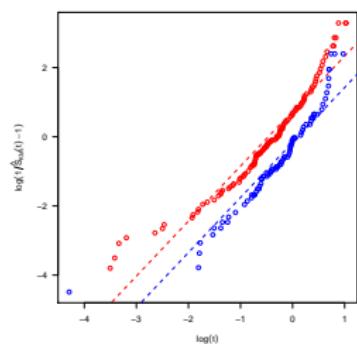
Para el conjunto de datos de cáncer de pulmón (considerando la covariable sexo)



WEI ( $R_a^2 = 0.958$ )



LN ( $R_a^2 = 0.899$ )



LL ( $R_a^2 = 0.915$ )



## Referencias Bibliográficas

# Referencias



# Referencias Bibliográficas

-  Aalen, O.O. (1978). Nonparametric Inference for a Family of Counting Processes. *Annals of Statistics*, **6**, 701-726.
-  Breslow, N. (1970). A generalized Kruskal-Wallis test for comparing K samples subject to unequal patterns of censorship. *Biometrika*, **57**, 579-594.
-  Dutang, C., Goulet, V., Pigeon, M. (2008). actuar: An R Package for Actuarial Science. *Journal of Statistical Software*, **25**, 1-37.
-  Gehan, E.A. (1965). A generalized Wilcoxon test for comparing arbitrarily singly-censored samples. *Biometrika*, **52**, 203-224.
-  Harrington, D.P., Fleming, T.R. (1982). A class of rank test procedures for censored survival data. *Biometrika*, **69**, 553-66.
-  Hosmer, D.W., Lemeshow, S. (1999). *Applied Survival Analysis*. John Wiley and Sons, New York.



## Referencias Bibliográficas

-  Hothorn T, Hornik K, van de Wiel MA, Zeileis A (2008). Implementing a class of permutation tests: The coin package. *Journal of Statistical Software*, **28**, 1-23.
-  Kalbfleish, J.D, Prentice, R.L. (1980). *The Statistical Analysis of Failure Time Data*. John Wiley and Sons, New York.
-  Kaplan, E.L., Meier, P. (1958). Nonparametric estimation from incomplete observations. *J. Amer. Statist. Assoc.*, **53**, 457-481.
-  Klein, J.P., Moeschberger, M.L. (1997). *Survival Analysis: Techniques for Censored and Truncated Data*. Springer-Verlag, New York.
-  Mantel, N. (1966). Evaluation of survival data and two new rank order statistics arising in its consideration. *Cancer Chemotherapy Reports*, **50**, 163-70.



# Referencias Bibliográficas

-  Millard SP (2013). EnvStats: An R Package for Environmental Statistics. Springer, New York. ISBN 978-1-4614-8455-4. URL: <https://www.springer.com>.
-  Nelson, W. (1972). Theory and Applications of Hazard Plotting for Censored Failure Data. *Technometrics*, **14**, 945-965.
-  Peto R., Peto J. (1972) Asymptotically efficient rank invariant test procedures. *J R Stat Soc A*, **135**, 185-198.
-  Prentice, R.L., Marek, P. (1979). A qualitative discrepancy between censored data rank tests. *Biometrics* **35**, 861-867.
-  Tarone, R.E., Ware, J. (1977) On Distribution-Free Tests for Equality of Survival Distributions. *Biometrika*, **64**, 156-160.
-  Therneau T (2020). A Package for Survival Analysis in R. R package version 3.1-12. URL: <https://CRAN.R-project.org/package=survival>.

