

# Análisis de Series Temporales y sus aplicaciones en R

*Clase 1*

Felipe Elorrieta López

Universidad de Santiago de Chile

Jun 28, 2023



**ALeRCE**  
Automatic Learning for the  
Rapid Classification of Events

CIRAS  
● ... : ● ● ..

DATA SALUD  
USACH



# Contenidos

Componentes de series de tiempo

Modelos ARIMA

Librerías de Series Temporales en R

Análisis Exploratorio Series Temporales

Aplicación en Datos Climáticos

Aplicación en Series de Tiempo Financieras

# ¿Que es una serie temporal?

- ▶ En muchos fenómenos naturales o sociales podemos medir ciertas variables y asignar un valor numérico a cada observación. Cuando hacemos esto, podemos hablar de una serie de observaciones  $\{y_t\}$  medidas secuencialmente en el tiempo.
- ▶ Por simplicidad, llamaremos serie de tiempo o serie cronologica a cualquier conjunto de observaciones numéricas  $\{y_t, t \in T\}$  **ordenadas en el tiempo**, es decir la variable tiempo  $t$  es estrictamente creciente.

# Componentes de series de tiempo


- ▶ Nivel
- ▶ Tendencia
- ▶ Estacionalidad
- ▶ Componente Aleatoria
- ▶ Lo cual puede ser expresado por la siguiente ecuación,

$$Y_t = N_t + T_t + S_t + \epsilon_t$$


- ▶ Este modelo lleva el nombre de modelo aditivo, ya que la serie de tiempo se puede descomponer en la suma de cada uno de estos componentes.

# Componentes de series de tiempo


**Sunspots**




**U.S. Population (millions)**



**CO<sub>2</sub>**



**Air Passengers**



# Procesos Estacionarios

- ▶ Un proceso estocástico  $Y(t)$  se dice **estrictamente estacionario** (o estacionario en el sentido fuerte) si todas las distribuciones de dimensión finita permanecen iguales en el tiempo, es decir,

$$F(Y_{k+1}, Y_{k+2}, \dots, Y_{k+n}) = F(Y_1, Y_2, \dots, Y_n) \quad \forall n, k \in \mathbb{Z}$$

# Procesos Estacionarios

- ▶ Un proceso estocástico  $Y(t)$  se dice **estrictamente estacionario** (o estacionario en el sentido fuerte) si todas las distribuciones de dimensión finita permanecen iguales en el tiempo, es decir,

$$F(Y_{k+1}, Y_{k+2}, \dots, Y_{k+n}) = F(Y_1, Y_2, \dots, Y_n) \quad \forall n, k \in \mathbb{Z}$$





- ▶ Un proceso estocástico  $Y(t)$  se dice **debilmente estacionario** (o estacionario de segundo orden) si,

1.  $\mathbb{E}[Y_t] = \mu = cte < \infty \quad \forall t \in \mathcal{T}$
2.  $\mathbb{V}[Y_t] = \sigma^2 = cte < \infty \quad \forall t \in \mathcal{T}$
3. Existe una función  $\gamma(\cdot)$  tal que  
$$\text{Cov}(Y_t, Y_s) = \gamma(t - s) \quad \forall t, s \in \mathcal{T}$$

# Función de Autocorrelación

- ▶ La Función de Autocorrelación (ACF) nos permite estudiar la estructura de dependencia temporal de una serie de tiempo.  
En R se calcula como:

```
acf(y,lag.max=20)
```



# Test de Box-Ljung

- ▶ Sea la Hipotesis

$$\begin{aligned} H_0 & : \rho(1) = \rho(2) = \dots = \rho(L) = 0 \text{ vs} \\ H_1 & : \exists i = 1, \dots, L : \rho(i) \neq 0 \end{aligned}$$

- ▶ el estadístico de Box-Lung es el siguiente,

$$Q_y = n(n+2) \sum_{j=1}^L \frac{\hat{\rho}^2(j)}{n-j}$$

donde  $\hat{\rho}(j)$  es la autocorrelación estimada para el  $j$ -ésimo lag.

- ▶ bajo  $H_0$ ,  $Q \sim \chi_L^2$ .

# Modelo ARMA

- ▶ Sea un proceso estocástico  $\{Y_t\}$ ,  $t \in T$  definido por la ecuación

$$Y_t - \phi_1 Y_{t-1} - \dots - \phi_p Y_{t-p} = \epsilon_t + \theta_1 \epsilon_{t-1} + \dots + \theta_q \epsilon_{t-q} \quad (1)$$

el cual es una combinación de un proceso AR( $p$ ) y un proceso MA( $q$ ) se conoce como "Modelo Autoregresivo de medias móviles"(ARMA( $p, q$ )),

donde  $\{\epsilon_t\} \sim RB$  y  $\phi_1, \dots, \phi_p, \theta_1, \dots, \theta_q$  son coeficientes fijos (a estimar).

# Modelo ARMA

- ▶ Sea un proceso estocástico  $\{Y_t\}$ ,  $t \in T$  definido por la ecuación

$$Y_t - \phi_1 Y_{t-1} - \dots - \phi_p Y_{t-p} = \epsilon_t + \theta_1 \epsilon_{t-1} + \dots + \theta_q \epsilon_{t-q} \quad (1)$$

el cual es una combinación de un proceso AR( $p$ ) y un proceso MA( $q$ ) se conoce como "Modelo Autoregresivo de medias móviles"(ARMA( $p, q$ )),





donde  $\{\epsilon_t\} \sim RB$  y  $\phi_1, \dots, \phi_p, \theta_1, \dots, \theta_q$  son coeficientes fijos (a estimar).

- ▶ Note que si  $p = 0$  el modelo ARMA( $p, q$ ) se reduce a un modelo MA( $q$ ) y si  $q = 0$  el modelo ARMA( $p, q$ ) se reduce a un modelo AR( $p$ )

# Modelo ARMA

- ▶ Se puede identificar el proceso ARMA apropiado para nuestros datos usando la ACF y la PACF bajo la siguiente estructura,

| Modelo    | ACF                     | PACF                    |
|-----------|-------------------------|-------------------------|
| AR(p)     | Decaim. Exp             | $0 \quad \forall k > p$ |
| MA(q)     | $0 \quad \forall k > q$ | Decaim. Exp             |
| ARMA(p,q) | Decaim. Exp             | Decaim. Exp             |

ACF AR(1):  $\phi = 0.8$ ACF MA(1):  $\theta = 0.8$ PACF AR(1):  $\phi = 0.8$ PACF MA(1):  $\theta = 0.8$ 

# Raiz Unitaria

- ▶ En un proceso  $y_t \sim AR(1)$  definido por  $y_t = \phi y_{t-1} + \epsilon_t$ , si  $|\phi| < 1$  entonces  $\{y_t\}$  es estacionario.
- ▶ Que sucede si  $\phi = 1$ ?

# Raiz Unitaria

- ▶ En un proceso  $y_t \sim AR(1)$  definido por  $y_t = \phi y_{t-1} + \epsilon_t$ , si  $|\phi| < 1$  entonces  $\{y_t\}$  es estacionario.
- ▶ Que sucede si  $\phi = 1$ ?
- ▶ Tenemos que  $y_t = y_{t-1} + \epsilon_t$ . En este caso decimos que  $y_t$  es un proceso de caminata aleatoria.
- ▶ Un proceso de caminata aleatoria es un proceso no estacionario.

## Raiz Unitaria

- ▶ En un proceso  $y_t \sim AR(1)$  definido por  $y_t = \phi y_{t-1} + \epsilon_t$ , si  $|\phi| < 1$  entonces  $\{y_t\}$  es estacionario.
- ▶ Que sucede si  $\phi = 1$ ?
- ▶ Tenemos que  $y_t = y_{t-1} + \epsilon_t$ . En este caso decimos que  $y_t$  es un proceso de caminata aleatoria.
- ▶ Un proceso de caminata aleatoria es un proceso no estacionario.
- ▶ Los test de Raíz unitaria permiten verificar la siguiente hipótesis:

$$H_0 : \phi = 1 \quad \text{vs} \quad H_1 : \phi < 1$$

- ▶ o equivalentemente,

$$H_0 : \text{Caminata Aleatoria} \quad \text{vs} \quad \text{Proceso Estacionario}$$

el más conocido de estos test, es el test de Dickey Fuller.

# Modelos ARIMA

- ▶ Sea  $x_t = (1 - B)^d y_t$  y suponga que  $x_t \sim ARMA(p, q)$ , es decir

$$\Phi_p(B)x_t = \Theta_q(B)\epsilon_t$$

donde  $\epsilon_t \sim RB(0, \sigma^2)$ , entonces podemos reescribir el proceso como,

$$\Phi_p(B)(1 - B)^d y_t = \Theta_q(B)\epsilon_t$$

- ▶ Este proceso  $\{y_t\}$  se conoce como “Autoregresivo integrado de medias móviles” y se denota como  $\{y_t\} \sim ARIMA(p,d,q)$

# Modelo SARIMA

- ▶ Decimos que  $\{y_t\}$  sigue un proceso SARIMA( $p, d, q$ )  $\times$  ( $P, D, Q$ )<sub>S</sub> si puede escribirse como,

$$\phi_p(B)\Phi_P(B^S)(1 - B)^d(1 - B^S)^D Y_t = \theta_q(B)\Theta_Q(B^S)\epsilon_t \quad (2)$$

- ▶ donde

$$\begin{aligned}
 \phi_p(B) &= 1 - \phi_1 B - \dots - \phi_p B^p \\
 \Phi_P(B^S) &= 1 - \Phi_1 B^S - \dots - \Phi_P B^{PS} \\
 \theta_q(B) &= 1 + \theta_1 B + \dots + \theta_q B^q \\
 \Theta_Q(B^S) &= 1 + \Theta_1 B + \dots + \Theta_Q B^{QS}
 \end{aligned}$$

# Modelo SARIMA


- Decimos que  $\{y_t\}$  sigue un proceso SARIMA( $p, d, q$ )  $\times$  ( $P, D, Q_S$ ) si puede escribirse como,  
 Polinomio Autoregresivo      Orden de Integracion      Polinomio de Medias Moviles

$$\phi_p(B)\Phi_P(B^S)(1 - B)^d(1 - B^S)^D Y_t = \theta_q(B)\Theta_Q(B^S)\varepsilon_t \quad (2)$$

- donde
  - Polinomio Autoregresivo Estacional
  - Orden de Integracion Estacional
  - Polinomio de Medias Moviles Estacional


$$\begin{aligned}
 \phi_p(B) &= 1 - \phi_1 B - \dots - \phi_p B^p \\
 \Phi_P(B^S) &= 1 - \Phi_1 B^S - \dots - \Phi_P B^{PS} \\
 \theta_q(B) &= 1 + \theta_1 B + \dots + \theta_q B^q \\
 \Theta_Q(B^S) &= 1 + \Theta_1 B + \dots + \Theta_Q B^{QS}
 \end{aligned}$$

# Metodología de Box y Jenkins



**FIGURE 1.7** Stages in the iterative approach to model building.

# Metodología de Box y Jenkins



**Forecasting System:  
The Model-Building and The Forecasting Phases**


# Librerías de Series Temporales en R

- ▶ **TSA:** Cryer and Chan (2010, 2nd ed) Time series analysis with applications in R
- ▶ **astsa:** Shumway and Stoffer (2017, 4th ed) Time Series Analysis and Its Applications: With R Examples
- ▶ **forecast:** by Rob Hyndman et al.
- ▶ **fUnitRoots:** by Diethelm Wuertz et al.
- ▶ **rugarch:** by Alexios Galanos
- ▶ **Imtest:** by Torsten Hothorn et al.

## Aplicación

- ▶ Serie de Temperatura Promedio Mensual medida en la estación Arturo Merino Benítez entre Enero de 1976 y Abril de 2023.

Temperatura Promedio Estacion Arturo Merino Benitez



# Función Auto-ARIMA


```
model=auto.arima(Temp)
```

Series: Temp

ARIMA(2,0,2)(0,1,1)[12]



Coefficients:

|            | ar1     | ar2     | ma1     | ma2    | sma1                     |
|------------|---------|---------|---------|--------|--------------------------|
|            | 1.4955  | -0.5991 | -1.2706 | 0.4657 | -0.8675                  |
| s.e.       | 0.2599  | 0.2224  | 0.2723  | 0.1886 | 0.0272                   |
| $\sigma^2$ | 0.6877  |         |         |        |                          |
|            |         |         |         |        | log likelihood = -690.89 |
| AIC        | 1393.78 |         |         |        | BIC=1419.7               |
| AICc       | 1393.93 |         |         |        |                          |



# Aplicación

```
y=log(Temp)
par(mfrow=c(2,1))
acf(y,lag.max=50,lwd=2,main="")
pacf(y,lag.max=50,lwd=2,main="")
```



# Test de Raíz Unitaria

```
require(fUnitRoots)
adfTest(y, lags = 1, type = c("nc"))
```

Title:  
Augmented Dickey-Fuller Test

Test Results:

PARAMETER:

Lag Order: 1

STATISTIC:

Dickey-Fuller: -1.7525

P VALUE:

0.07992

```
adfTest(y, lags = 12, type = c("nc"))
```

Title:  
Augmented Dickey-Fuller Test

Test Results:

PARAMETER:

Lag Order: 12

STATISTIC:

Dickey-Fuller: 0.4029



P VALUE:

0.7447

# Test de Raíz Unitaria

| Serie                 | $X_t$ | $\nabla X_t$ | $\nabla_{12} X_t$ | $\nabla_{12} \nabla X_t$ | $\nabla^2 X_t$ | $\nabla_{12}^2 \nabla X_t$ |
|-----------------------|-------|--------------|-------------------|--------------------------|----------------|----------------------------|
| adfTest(., lags = 1)  | 0.08  | 0.01         | 0.01              | 0.01                     | 0.01           | 0.01                       |
| adfTest(., lags = 12) | 0.75  | 0.01         | 0.01              | 0.01                     | 0.01           | 0.01                       |
| Stdev                 | 0.116 | 0.039        | 0.009             | 0.014                    | 0.033          | 0.027                      |

- ▶ La solución de mínima varianza es  $d = 0$  y  $D = 1$ .



# Modelo Propuesto

- ▶ SARIMA(1, 0, 1)  $\times$  (0, 1, 1)<sub>12</sub>

```
model4=arima(y,order=c(1,0,1),seasonal=list(order=c(0,1,1),period=12))
summary(model4)
Call:
arima(x = y, order = c(1, 0, 1), seasonal = list(order = c(0, 1, 1),
, period = 12))
Coefficients:
          ar1      ma1      sma1
          0.7471 -0.5213 -0.8958
  s.e.  0.0836  0.1033  0.0264
```

- ▶ Significancia de Parametros


```
require(lmtest)
coeftest(model4)
z test of coefficients:
```

|      | Estimate  | Std. Error | z value  | Pr(> z )      |
|------|-----------|------------|----------|---------------|
| ar1  | 0.747089  | 0.083583   | 8.9383   | < 2.2e-16 *** |
| ma1  | -0.521283 | 0.103272   | -5.0477  | 4.472e-07 *** |
| sma1 | -0.895826 | 0.026441   | -33.8801 | < 2.2e-16 *** |


# Diagnóstico del Modelo

`tsdiag(model4,gof.lag=36)`


Standardized Residuals



ACF of Residuals




p values for Ljung-Box statistic




# Forecast

```
Forecast<-predict(model4,n.ahead=24)
```




# Validacion

- ▶ Para evaluar la capacidad predictiva del modelo propuesto, usaremos el primer 90 % de la serie para entrenar el modelo propuesto y el 10 % para validararlo.




# Validacion

- ▶ Para evaluar la capacidad predictiva del modelo propuesto, usaremos el primer 90 % de la serie para entrenar el modelo propuesto y el 10 % para validararlo.



# Aplicación en Series de Tiempo Financieras

- ▶ Serie del Precio de cierre diario de Falabella en la Bolsa de Santiago observado entre el 14 jun 2018 y el 14 jun 2023.



# Retornos de Activos


- ▶ Sea  $P_t$ : El precio de un activo.
- ▶ Se define el retorno simple a un periodo: desde la fecha  $t - 1$  a  $t$  como,

$$R_t = \frac{P_t}{P_{t-1}} - 1 = \frac{P_t - P_{t-1}}{P_{t-1}}$$

- ▶ También es posible obtener el retorno compuesto continuamente a través de:  $R_t = \log P_t - \log P_{t-1}$ . Este es el retorno comúnmente usado.

# Retornos de Activos

Retorno Compuesto Continuamente Cierre Falabella



# Hechos Estilizados

- ▶ Las series financieras suelen presentar las siguientes características, generalmente conocidos como los hechos estilizados (stylized-facts).
  1. **Ausencia de autocorrelación significativa:** Las series financieras (retornos), exhiben bajo nivel de autocorrelación, por lo cual tienen bajo nivel de predicción.
  2. **Distribuciones con colas pesadas:** Por lo general las series financieras tienen mucho más kurtosis que la de un ruido blanco gaussiano.
  3. **Agrupamiento de la volatilidad:** La volatilidad es persistente y puede ser alta para ciertos periodos de tiempo y baja para otros. Esta característica se puede ver reflejada en las autocorrelaciones de la serie al cuadrado significativamente distintas de cero.

# Proceso GARCH

- ▶ El proceso GARCH(p,q) está dado por.


$$\begin{aligned} r_t &= \sigma_t \epsilon_t \\ \sigma_t^2 &= \alpha_0 + \sum_{i=1}^p \alpha_i r_{t-i}^2 + \sum_{j=1}^q \beta_j \sigma_{t-j}^2 \end{aligned}$$

- ▶ donde  $\epsilon_t$  iid  $N(0, 1)$ ,  $\alpha_0 > 0$ ,  $\alpha_i \geq 0$ ,  $i = 1, \dots, p$ ,  $\beta_j \geq 0$ ,  $j = 1, \dots, q$  y  $\sum_{i=1}^{\max\{p,q\}} (\alpha_i + \beta_j) < 1$ .
- ▶ Si  $q = 0$ , el modelo anterior se reduce al siguiente modelo ARCH(p).





$$\begin{aligned} r_t &= \sigma_t \epsilon_t \\ \sigma_t^2 &= \alpha_0 + \alpha_1 r_{t-1}^2 + \alpha_2 r_{t-2}^2 + \dots + \alpha_p r_{t-p}^2 \end{aligned}$$

# Hechos Estilizados

Retorno Compuesto Continuamente Cierre Falabella




# Hechos Estilizados




# Hechos Estilizados

Distribucion Retornos



Normal Q-Q Plot



# Ajuste Modelo GARCH

```
library(rugarch)
spec<-ugarchspec(variance.model=list(model="sGARCH",garchOrder = c(1, 1)),
mean.model=list(armaOrder=c(0,0),include.mean=FALSE),distribution.model="norm")
fit<-ugarchfit(data=rtn,spec=spec)
show(fit)
```

Conditional Variance Dynamics

GARCH Model : sGARCH(1,1)

Mean Model : ARFIMA(0,0,0)

Distribution : norm

Optimal Parameters

|        | Estimate | Std. Error | t value | Pr(> t ) |
|--------|----------|------------|---------|----------|
| omega  | 0.000014 | 0.000003   | 4.7746  | 2e-06    |
| alpha1 | 0.171198 | 0.023661   | 7.2354  | 0e+00    |
| beta1  | 0.816755 | 0.018999   | 42.9885 | 0e+00    |

Weighted Ljung-Box Test on Standardized Residuals

|                         | statistic | p-value  |
|-------------------------|-----------|----------|
| Lag[1]                  | 8.649     | 0.003272 |
| Lag[2*(p+q)+(p+q)-1][2] | 8.698     | 0.004225 |
| Lag[4*(p+q)+(p+q)-1][5] | 8.869     | 0.017864 |

# Modelo ARMA-GARCH

- ▶ Las series financieras que presentan baja correlación se le ajusta un modelo ARMA cuyas innovaciones son un proceso GARCH. Por lo tanto el modelo  $ARMA(p_1, q_1) - GARCH(p_2, q_2)$  a utilizar esta dado por,

$$r_t = \phi_1 r_{t-1} + \phi_2 r_{t-2} + \dots + \phi_{p_1} r_{t-p_1} + \theta_1 \epsilon_{t-1} + \dots + \theta_{q_1} \epsilon_{t-q_1}$$

$$\epsilon_t = \nu_t \epsilon_t$$

$$\sigma_t^2 = \alpha_0 + \sum_{i=1}^{p_2} \alpha_i \epsilon_{t-i}^2 + \sum_{j=1}^{q_2} \beta_j \sigma_{t-j}^2$$





.

# Ajuste Modelo ARMA-GARCH

```
spec<-ugarchspec(variance.model=list(model="sGARCH",garchOrder = c(1, 1)),  
mean.model=list(armaOrder=c(1,0),include.mean=FALSE),distribution.model="norm")  
fit=ugarchfit(data=rtn,spec=spec)  
show(fit)  
Conditional Variance Dynamics  
-----  
GARCH Model : sGARCH(1,1)  
Mean Model : ARFIMA(1,0,0)  
Distribution : norm  
Optimal Parameters  
-----  
Estimate Std. Error t value Pr(>|t|)  
ar1 0.064653 0.031264 2.0680 0.038641  
omega 0.000014 0.000003 4.7405 0.000002  
alpha1 0.170418 0.023587 7.2252 0.000000  
beta1 0.817501 0.019169 42.6472 0.000000  
Weighted Ljung-Box Test on Standardized Residuals  
-----  
statistic p-value  
Lag[4*(p+q)+(p+q)-1][5] 1.385 0.8737  
Weighted Ljung-Box Test on Standardized Squared Residuals  
-----  
statistic p-value  
Lag[2*(p+q)+(p+q)-1][5] 0.46432 0.9630
```

# Análisis de Residuos





`plot(fit)`




# Ajuste Modelo ARMA-GARCH con errores no-normales

```
spec<-ugarchspec(variance.model=list(model="sGARCH",garchOrder = c(1, 1)),  
mean.model=list(armaOrder=c(1,0),include.mean=FALSE),distribution.model="std")  
fit=ugarchfit(data=rtn,spec=spec)  
show(fit)  
Conditional Variance Dynamics  
-----  
GARCH Model : sGARCH(1,1)  
Mean Model : ARFIMA(1,0,0)  
Distribution : std  
  
Optimal Parameters  
-----  
Estimate Std. Error t value Pr(>|t|)  
ar1 0.101349 0.029373 3.4504 0.000560  
omega 0.000008 0.000004 1.9136 0.055676  
alpha1 0.139902 0.028678 4.8784 0.000001  
beta1 0.859096 0.026840 32.0085 0.000000  
shape 4.742920 0.688817 6.8856 0.000000
```

# Análisis de Residuos





# Volatilidad Estimada



# Forecast

```
forc = ugarchforecast(fit, n.ahead=10)
plot(forc)
```





**SOCHE**   
SOCIEDAD CHILENA DE ESTADÍSTICA

**MINICURSO ONLINE**

**ANÁLISIS DE SERIES TEMPORALES Y SUS APLICACIONES EN R**

**FELIPE ELORRIETA** 

PROFESOR ASOCIADO USACH

 Miércoles  
5 de julio  
11:30

**TEMARIO**

- Aplicaciones en Finanzas 2:
  - Análisis Multivariado de Series Temporales.
  - Modelos VAR-VARMA
- Aplicaciones en Salud
  - Análisis de Series de Tiempo Interrumpidas
- Aplicaciones en Astronomía:
  - Series de Tiempo Irregularmente Observadas.
  - Periodograma
  - Modelos IAR

**CERTIFICADO GRATUITO PARA SOCIOS ACTIVOS SOCHE**  
**PERSONAS EXTERNAS A LA SOCHE TIENE UN COSTO DE \$5.000.**  
**INSCRIPCIONES EN NUESTRA WEB [WWW.SOCHE.CL](http://WWW.SOCHE.CL)**

• • • •

tusind tak  
谢謝 dakujem vám  
ありがとう  
nгигиабонга  
thank you  
gracias  
obrigada  
obrigado  
teşekkür ederim  
شکرا  
tack så mycket  
dziekuję  
merci  
baie dankie  
ধন্যবাদ  
molte grazie  
dank u  
dank u  
dank u  
mahalo  
teşekkür edire  
gràcies  
tänan  
dank u  
teşekkür edire



felipe.elorrieta@usach.cl



@felipeelorrieta